

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

Chắt lọc tri thức có trọng số theo lớp từ mô hình
ngôn ngữ lớn sang mô hình nhỏ

ĐÀO QUỐC TUẤN

tuan.dq210891@sis.hust.edu.vn

Chương trình đào tạo: Tài năng Khoa học máy tính

Giảng viên hướng dẫn: TS. Ngô Văn Linh

Chữ kí GVHD

Khoa:

Khoa học máy tính

Trường:

Công nghệ Thông tin và Truyền thông

HÀ NỘI, 10/2025

LỜI CẢM ƠN

Trong suốt quá trình thực hiện đồ án tốt nghiệp, em đã nhận được rất nhiều sự quan tâm, hỗ trợ và những ý kiến đóng góp quý báu từ thầy cô, gia đình và bạn bè. Em xin bày tỏ lòng biết ơn sâu sắc tới gia đình – những người luôn ở bên, đồng hành và tiếp thêm cho em động lực trong suốt chặng đường vừa qua. Em xin cảm ơn bố mẹ, em gái và người thương, những người đã trở thành chỗ dựa tinh thần vững chắc, giúp em vượt qua những thời điểm khó khăn.

Quãng thời gian học tập tại Trường Đại học Bách Khoa Hà Nội cũng như quá trình thực hiện đồ án tốt nghiệp đối với em là những kỷ niệm đáng trân trọng. Những kiến thức và trải nghiệm tích lũy được trong thời gian này sẽ là hành trang quý báu cho em trên con đường học tập và làm việc sau này. Em xin chân thành cảm ơn các thầy cô và bạn bè đã luôn đồng hành, giúp đỡ và chia sẻ cùng em trong suốt quá trình học tập. Đặc biệt, em xin gửi lời cảm ơn chân thành tới Thầy Ngô Văn Linh, người đã tận tình hướng dẫn, hỗ trợ và tạo điều kiện để em có thể hoàn thành đồ án này.

Em cũng xin cảm ơn những người bạn, anh chị em đã gắn bó cùng em trong suốt bốn năm qua, cùng nhau học tập, sinh hoạt và chia sẻ những niềm vui, nỗi buồn trong cuộc sống sinh viên. Sự đồng hành và giúp đỡ của mọi người là yếu tố quan trọng giúp em hoàn thành tốt đồ án tốt nghiệp. Cuối cùng, em xin gửi lời cảm ơn tới ngôi trường nơi em đã theo học – Trường Đại học Bách Khoa Hà Nội – nơi đã mang đến cho em môi trường học tập, rèn luyện và trưởng thành.

TÓM TẮT NỘI DUNG ĐỒ ÁN

Chắt lọc tri thức (Knowledge Distillation) trong lĩnh vực mô hình ngôn ngữ lớn (Large Language Models – LLM) là một kỹ thuật quan trọng nhằm giảm kích thước mô hình và tài nguyên tính toán, trong khi vẫn đảm bảo chất lượng đầu ra. Phương pháp này nén mô hình bằng cách truyền tri thức từ mô hình “giáo viên” có quy mô lớn sang mô hình “học sinh” nhỏ hơn. Dù vậy, các phương pháp chắt lọc tri thức truyền thống vẫn gặp thách thức khi mô hình giáo viên và học sinh có sự khác biệt về bộ từ vựng và tokenizer, dẫn đến việc căn chỉnh tri thức không hiệu quả. Một số hướng tiếp cận chắt lọc tri thức có căn chỉnh tokenizer (Cross-Tokenizer Knowledge Distillation - CTKD) gần đây đã được đề xuất để khắc phục vấn đề này, song vẫn còn tồn tại các hạn chế như cản trở phân phối, bỏ qua cấu trúc tầng trung gian, hoặc chỉ dựa trên các ánh xạ tầng đơn giản.

Đồ án này đề xuất một phương pháp chắt lọc có nhận thức về tầm quan trọng của các tầng mô hình, nhằm tăng cường khả năng truyền tri thức giữa các mô hình có độ sâu và kích thước khác nhau. Phương pháp tập trung xác định và gán trọng số cho các tầng có mức ảnh hưởng lớn của mô hình giáo viên, giúp mô hình học sinh học tập hiệu quả hơn các đặc trưng quan trọng. Đồng thời, giải pháp cũng xử lý sự khác biệt về từ vựng thông qua phép chiếu dựa trên các token trùng lặp, và căn chỉnh các đoạn token có trọng số dựa trên độ tương đồng của embedding và trạng thái ẩn, giúp cải thiện quá trình truyền tri thức giữa các bộ tokenizer khác nhau.

Kết quả thực nghiệm trên các bộ dữ liệu instruction-following cho thấy phương pháp này đạt hiệu năng cao hơn so với các hướng tiếp cận chắt lọc tri thức có căn chỉnh tokenizer hiện có, góp phần nâng cao chất lượng và tính tổng quát trong quá trình nén và huấn luyện mô hình ngôn ngữ lớn.

Sinh viên thực hiện
(Ký và ghi rõ họ tên)

ABSTRACT

Knowledge Distillation (KD) in the field of Large Language Models (LLMs) is an important technique aimed at reducing model size and computational resources while maintaining the quality of responses. Knowledge Distillation is considered an effective approach for model compression by transferring knowledge from a large-scale "teacher" model to a smaller "student" model. However, traditional knowledge distillation methods still face challenges when teacher and student models differ in vocabulary and tokenizer, leading to inefficient knowledge alignment. Several Cross-Tokenizer Knowledge Distillation (CTKD) approaches have recently been proposed to address this issue; however, they still suffer from limitations such as truncated distributions, neglect of intermediate layer structures, or reliance on simple one-to-one layer mappings.

This project proposes a distillation method with awareness of model layer importance, aiming to enhance knowledge transfer capability between models with different depths and sizes. The method focuses on identifying and assigning weights to highly influential layers of the teacher model, enabling the student model to learn important features more effectively. Simultaneously, the solution also handles vocabulary differences through projections based on overlapping tokens, and aligns weighted token spans based on embedding and hidden state similarities, improving the knowledge transfer process between different tokenizers.

Experimental results on instruction-following datasets demonstrate that this method achieves higher performance compared to existing Cross-Tokenizer Knowledge Distillation approaches, contributing to improved quality and generalization in the compression and training process of large language models.

MỤC LỤC

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI.....	1
1.1 Đặt vấn đề.....	1
1.2 Các giải pháp hiện tại và hạn chế	1
1.3 Mục tiêu và định hướng giải pháp	2
1.4 Đóng góp của đồ án	3
1.5 Bố cục đồ án	3
CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT	5
2.1 Mô hình Ngôn ngữ Lớn (Large Language Models)	5
2.2 Hàm Softmax và hệ số nhiệt độ (Temperature Scaling).....	6
2.3 Hàm mất mát chắt lọc tri thức (Knowledge Distillation Loss).....	7
2.4 Vận tải tối ưu (Optimal Transport) và Khoảng cách Wasserstein (Wasserstein Distance).....	8
2.5 Ngữ cảnh của bài toán.....	9
2.6 Các kết quả nghiên cứu tương tự	10
2.6.1 Phương pháp MultiOT (Multi-Level Optimal Transport).....	11
2.6.2 Phương pháp DSKD (Dual-Space Knowledge Distillation)	12
2.6.3 Phương pháp RAIL-KD (Random Intermediate Layer Knowledge Distillation)	14
CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT.....	18
3.1 Tổng quan giải pháp.....	18
3.2 Nhắc lại quy ước.....	19
3.3 Phép chiếu từ vựng (Vocabulary Projection).....	19
3.4 Căn chỉnh giữa các tầng (Layer Alignment).....	21
3.5 Căn chỉnh giữa các bộ mã hóa (Cross-Tokenizer Alignment).....	23
3.6 Hàm mục tiêu tổng thể (Overall Objective)	26

3.7 Tổng kết.....	27
CHƯƠNG 4. ĐÁNH GIÁ THỰC NGHIỆM.....	29
4.1 Dữ liệu huấn luyện và đánh giá	29
4.1.1 Dữ liệu huấn luyện	29
4.1.2 Dữ liệu đánh giá.....	29
4.2 Mô hình giáo viên và mô hình học sinh	30
4.2.1 Qwen1.5-1.8B (giáo viên) → GPT2-120M (học sinh).....	30
4.2.2 Mistral-7B (giáo viên) → TinyLLaMA-1.1B (học sinh)	30
4.2.3 Qwen2.5-7B-Instruct (giáo viên) → GPT-2 1.5B (học sinh)	30
4.2.4 Lý do lựa chọn	31
4.3 Chỉ số đánh giá ROUGE-L	31
4.3.1 Lựa chọn các phương pháp so sánh	32
4.3.2 Các tham số huấn luyện	33
4.4 Kết quả và Đánh giá.....	33
4.5 Một số kết quả khác	36
CHƯƠNG 5. KẾT LUẬN	39
5.1 Kết luận	39
5.2 Hướng phát triển trong tương lai	40
TÀI LIỆU THAM KHẢO.....	42

DANH MỤC HÌNH VẼ

Hình 2.1	Kiến trúc cơ bản của mô hình Transformer	5
Hình 2.2	Kiến trúc học chặt lọc tri thức giữa mô hình giáo viên và mô hình học sinh	7
Hình 2.3	Phương pháp RAIL-KD[3]	15
Hình 3.1	Quy trình tổng thể của phương pháp đề xuất	19

DANH MỤC BẢNG BIỂU

Bảng 4.1	Cấu hình huấn luyện chi tiết cho các cặp mô hình.	33
Bảng 4.2	So sánh hiệu quả các phương pháp chốt lọc trên ba cặp mô hình (ROUGE-L, trung bình 5 lần chạy).	34
Bảng 4.3	Ảnh hưởng của số tầng giáo viên và chiến lược khởi tạo trong W-CTKD (Qwen2.5-7B-Instruct → GPT2-1.5B).	35
Bảng 4.4	Một số kết quả so sánh giữa các phương pháp khác nhau với mô hình TinyLLaMA-1.1B.	37
Bảng 4.5	Một số kết quả so sánh giữa các phương pháp khác nhau với mô hình GPT2-1.5B.	38

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT

Thuật ngữ	Ý nghĩa
CTKD	Chắt lọc tri thức có căn chỉnh tokenizer (Cross-Tokenizer Knowledge Distillation)
DSKD	Chắt lọc tri thức Không gian Kép (Dual-Space Knowledge Distillation)
KD	Chắt lọc tri thức (Knowledge Distillation)
KL	Khoảng cách Kullback–Leibler
LCS	Dãy con chung dài nhất (Longest Common Subsequence)
LLM	Mô hình ngôn ngữ lớn (Large Language Model)
MultiOT	Vận chuyển Tối ưu Đa cấp (Multi-Level Optimal Transport)
ULD	Chắt lọc Logit Phổ quát (Universal Logit Distillation)

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1 Đặt vấn đề

Trong những năm gần đây, các mô hình ngôn ngữ lớn (Large Language Models - LLMs) đã đạt được nhiều tiến bộ vượt bậc trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP), đặc biệt ở các nhiệm vụ như theo dõi hướng dẫn, suy luận phức tạp và sinh văn bản tự nhiên. Các mô hình này, với số lượng tham số rất lớn, mang lại hiệu suất cao nhưng cũng đòi hỏi chi phí tính toán đáng kể cho cả quá trình huấn luyện và triển khai. Điều này làm hạn chế khả năng ứng dụng của chúng trong các môi trường có tài nguyên tính toán hạn chế như thiết bị di động, hệ thống nhúng hoặc các ứng dụng yêu cầu độ trễ thấp.

Chất lọc tri thức được xem là một hướng tiếp cận hiệu quả để nén mô hình, bằng cách chất lọc tri thức từ mô hình “giáo viên” có năng lực mạnh sang mô hình “học sinh” nhỏ hơn, giúp giảm kích thước mô hình mà vẫn duy trì được chất lượng dự đoán. Tuy nhiên, các phương pháp chất lọc tri thức truyền thống thường giả định rằng giáo viên và học sinh sử dụng cùng bộ tokenizer và cùng tập từ vựng. Khi giả định này không còn đúng, đặc biệt giữa các mô hình thuộc những họ khác nhau, quá trình chất lọc tri thức trở nên kém hiệu quả do sự lệch pha trong chuỗi token và khác biệt trong phân phối đầu ra.

Sự không tương thích giữa tokenizer và từ vựng khiến học sinh khó tái hiện không gian biểu diễn của giáo viên, làm giảm khả năng học tri thức ngữ nghĩa sâu. Do đó, cần có các phương pháp chất lọc tri thức linh hoạt hơn, có khả năng xử lý sự khác biệt này để tăng hiệu quả nén và mở rộng khả năng ứng dụng của các mô hình ngôn ngữ trong thực tế.

1.2 Các giải pháp hiện tại và hạn chế

Các phương pháp chất lọc tri thức truyền thống chủ yếu dựa trên việc thu hẹp khoảng cách giữa phân phối đầu ra của mô hình giáo viên và mô hình học sinh, thường thông qua các độ đo như Kullback–Leibler divergence hoặc Reverse Kullback–Leibler divergence. Những phương pháp này đạt hiệu quả cao trong trường hợp hai mô hình có kiến trúc, không gian biểu diễn hoặc tokenizer tương đồng. Tuy nhiên, khi tồn tại sự khác biệt đáng kể giữa mô hình giáo viên và mô hình học sinh, chẳng hạn như khác biệt về kiến trúc mạng, tokenizer, kích thước không gian ẩn hoặc vốn từ vựng, hiệu quả chất lọc thường suy giảm rõ rệt, từ đó ảnh hưởng tiêu cực đến chất lượng của mô hình học sinh.

Nhằm khắc phục hạn chế trên, các nghiên cứu gần đây đã đề xuất sử dụng

khoảng cách Wasserstein dựa trên lý thuyết vận tải tối ưu (Optimal Transport – OT) để thực hiện việc căn chỉnh phân phối giữa hai mô hình. Với đặc tính linh hoạt trong việc so khớp các phân phối có miền xác định khác nhau, OT cho phép xử lý hiệu quả hơn các tình huống không đồng nhất về kiến trúc và không gian biểu diễn. Bên cạnh đó, nhiều hướng tiếp cận hiện đại còn khai thác việc kết hợp đa dạng các hàm chi phí hoặc thiết kế bài toán tối ưu đa mục tiêu, nhằm đồng thời căn chỉnh các khía cạnh khác nhau như phân phối xác suất, cấu trúc cú pháp và thông tin ngữ nghĩa giữa mô hình giáo viên và mô hình học sinh.

Mặc dù vậy, phần lớn các phương pháp hiện có vẫn tập trung chủ yếu vào việc truyền tri thức thông qua căn chỉnh phân phối đầu ra, trong khi chưa khai thác đầy đủ tiềm năng của việc căn chỉnh các biểu diễn ẩn (hidden states) ở mức phân phối giữa hai mô hình. Trong bối cảnh các mô hình ngôn ngữ lớn, việc chỉ dựa vào thông tin đầu ra là chưa đủ để truyền tải trọn vẹn tri thức mà mô hình giáo viên đã học được. Việc đồng thời căn chỉnh cả phân phối đầu ra và các biểu diễn ẩn được xem là yếu tố then chốt, giúp mô hình học sinh tiếp thu tốt hơn các đặc trưng sâu về ngữ nghĩa và cấu trúc nội tại.

Do đó, bài toán căn chỉnh phân phối biểu diễn ẩn giữa các mô hình có sự khác biệt về kiến trúc, tokenizer và không gian biểu diễn vẫn đặt ra nhiều thách thức. Điều này cho thấy nhu cầu cấp thiết về các phương pháp chất lọc tri thức mới, vừa đảm bảo hiệu quả về mặt học thuật, vừa có tính khả thi và ứng dụng cao trong thực tiễn.

1.3 Mục tiêu và định hướng giải pháp

Mục tiêu của đề án là phát triển một khung chất lọc tri thức (Knowledge Distillation – KD) có khả năng xử lý sự khác biệt giữa tokenizer và từ vựng, đồng thời tận dụng hiệu quả thông tin đa lớp từ mô hình giáo viên. Mục tiêu chính là tăng cường khả năng căn chỉnh ngữ nghĩa giữa các token không tương ứng trực tiếp và giúp mô hình học sinh tập trung học từ các lớp giáo viên có mức độ ảnh hưởng lớn nhất.

Định hướng giải pháp của đề án tập trung vào ba khía cạnh chính: (1) Xử lý sự khác biệt về độ sâu bằng cách xếp hạng và trọng số hóa các lớp giáo viên theo mức độ đóng góp của chúng; (2) Giảm chênh lệch từ vựng bằng cách chiếu biểu diễn từ không gian của giáo viên sang không gian của học sinh thông qua các token chồng chéo; (3) Khắc phục sự không khớp tokenizer bằng căn chỉnh span có trọng số dựa trên độ tương đồng của embedding và trạng thái ẩn.

Những thành phần này được kết hợp trong một hàm mất mát tổng hợp, giúp mô hình học sinh học tập hiệu quả hơn trong quá trình chất lọc tri thức.

1.4 Đóng góp của đề án

Các đóng góp chính của đề án có thể được tóm tắt như sau:

1. Đề xuất một khung KD có khả năng nhận biết tầm quan trọng của các lớp giáo viên, giúp mô hình học sinh tập trung vào những lớp chứa tri thức cốt lõi và cải thiện hiệu quả chất lọc đa lớp.
2. Giải quyết sự không khớp giữa tokenizer và từ vựng thông qua cơ chế chiếu biểu diễn và căn chỉnh span có trọng số, đảm bảo tính ổn định và chính xác trong quá trình học.
3. Thực hiện đánh giá thực nghiệm trên các bộ dữ liệu và benchmark theo dõi hướng dẫn, chứng minh phương pháp đề xuất mang lại hiệu suất cao hơn so với các baseline CTKD hiện tại.

1.5 Bố cục đề án

Phần còn lại của báo cáo được tổ chức thành các chương như sau:

Chương 2 trình bày các khái niệm và nền tảng lý thuyết cần thiết cho đề tài, bao gồm hàm Softmax với hệ số nhiệt độ, cấu trúc hàm mất mát trong chất lọc tri thức, lý thuyết vận tải tối ưu (Optimal Transport) và khoảng cách Wasserstein. Bên cạnh đó, chương này cung cấp tổng quan về các mô hình ngôn ngữ lớn (Large Language Models – LLMs) nhằm làm cơ sở cho việc phát triển phương pháp đề xuất. Trên nền tảng đó, chương 2 phân tích bối cảnh bài toán và tổng hợp các công trình nghiên cứu liên quan, trong đó giới thiệu chi tiết ba phương pháp chất lọc tri thức tiêu biểu: Multi-Level Optimal Transport (MultiOT) [1], Dual-Space Knowledge Distillation (DSKD) [2] và Random Intermediate Layer Knowledge Distillation (RAIL-KD) [3].

Chương 3 trình bày phương pháp chất lọc tri thức được đề xuất trong đề án. Chương này tập trung vào việc khai thác trực tiếp các biểu diễn tầng ẩn của mô hình giáo viên nhằm chất lọc tri thức cho mô hình học sinh trong bối cảnh hai mô hình có sự khác biệt về kiến trúc và tokenizer. Cụ thể, chương mô tả cơ chế xây dựng phép chiếu từ vựng để căn chỉnh không gian biểu diễn giữa hai mô hình, chiến lược lựa chọn và ánh xạ các tầng ẩn quan trọng của mô hình giáo viên sang mô hình học sinh dựa trên mức độ ảnh hưởng của từng tầng, cũng như cách kết hợp thông tin ngữ cảnh ở mức token thông qua cơ chế căn chỉnh cross-tokenizer. Cuối cùng, chương xây dựng hàm mất mát tổng thể kết hợp giữa học có giám sát và chất lọc dựa trên biểu diễn tầng ẩn, giúp mô hình học sinh tiếp thu hiệu quả tri thức ngữ nghĩa sâu từ mô hình giáo viên ngay cả khi hai mô hình không sử dụng chung bộ từ vựng.

Chương 4 tập trung vào đánh giá thực nghiệm của phương pháp đề xuất. Chương này mô tả chi tiết dữ liệu huấn luyện và đánh giá, cùng với các cặp mô hình giáo viên–học sinh được sử dụng trong thí nghiệm, bao gồm: Qwen1.5-1.8B [4] → GPT2-120M [5], Mistral-7B [6] → TinyLLaMA-1.1B [7], và Qwen2.5-7B-Instruct [8] → GPT2-1.5B [5], kèm theo phân tích lý do lựa chọn. Ngoài ra, chương cũng trình bày chi tiết chỉ số đánh giá ROUGE-L, bao gồm khái niệm, phương pháp tính toán và ý nghĩa ứng dụng. Cuối cùng, các phương pháp so sánh, thiết lập tham số huấn luyện và kết quả thực nghiệm được báo cáo kèm theo phân tích và đánh giá chuyên sâu.


Chương 5 tổng kết các nội dung chính và những đóng góp nổi bật của nghiên cứu. Chương này nhấn mạnh hiệu quả của phương pháp W-CTKD trong việc cải thiện khả năng chất lọc tri thức giữa các mô hình ngôn ngữ lớn có kích thước và cấu trúc khác nhau. Đồng thời, một số hướng phát triển trong tương lai cũng được đề xuất, bao gồm mở rộng phương pháp sang các lĩnh vực ngoài xử lý ngôn ngữ tự nhiên, nghiên cứu các kỹ thuật ước lượng ma trận chi phí hiệu quả hơn, và tối ưu hóa thuật toán để áp dụng cho các mô hình có quy mô rất lớn.

CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT

Chương này trình bày bài toán chất lọc tri thức, các kiến thức nền tảng và các nghiên cứu liên quan, làm cơ sở cho phương pháp được đề xuất trong đề án.

2.1 Mô hình Ngôn ngữ Lớn (Large Language Models)

Mô hình ngôn ngữ lớn (Large Language Model – LLM) là một lớp mô hình trí tuệ nhân tạo có khả năng hiểu, xử lý và sinh ngôn ngữ tự nhiên ở mức độ gần với con người. Các LLM hiện đại thường được huấn luyện trên các tập dữ liệu văn bản quy mô rất lớn, cho phép mô hình học được ngữ cảnh, cấu trúc cú pháp cũng như ngữ nghĩa của ngôn ngữ.



Hình 2.1: Kiến trúc cơ bản của mô hình Transformer

Phần lớn các LLM hiện nay đều được xây dựng dựa trên kiến trúc Transformer. Kiến trúc này bao gồm nhiều tầng (layer) sử dụng cơ chế self-attention, cho phép

mô hình nắm bắt mối quan hệ giữa các token trong chuỗi, kể cả khi khoảng cách giữa chúng là rất xa. Nhờ đó, Transformer có khả năng mô hình hóa ngữ cảnh dài và phức tạp một cách hiệu quả.

Quy trình xử lý dữ liệu trong LLM bắt đầu bằng việc ánh xạ các token đầu vào sang không gian vector thông qua kỹ thuật embedding. Sau đó, thông tin vị trí (positional encoding) được bổ sung để cung cấp thứ tự tuần tự của các token, do embedding thuần túy không chứa thông tin vị trí. Dữ liệu tiếp tục được truyền qua nhiều tầng Transformer, bao gồm các khối self-attention và các lớp fully connected, nhằm học các biểu diễn ngôn ngữ ở mức độ ngày càng trừu tượng.

Cuối cùng, mô hình sinh văn bản bằng cách dự đoán xác suất của token tiếp theo dựa trên toàn bộ ngữ cảnh đã quan sát trước đó.

2.2 Hàm Softmax và hệ số nhiệt độ (Temperature Scaling)

Hàm softmax là một hàm kích hoạt thường được sử dụng trong các mô hình học máy nhằm ánh xạ các giá trị đầu ra dạng logits của mô hình thành một phân phối xác suất trên không gian các lớp. Với một vectơ logits $\mathbf{z} = [z_1, z_2, \dots, z_K]$ gồm K phần tử, xác suất dự đoán tương ứng với lớp i được xác định như sau:

$$p_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}. \quad (2.1)$$

Hàm softmax đảm bảo tổng các xác suất bằng 1 và làm nổi bật lớp có giá trị logit lớn nhất, từ đó cho phép mô hình đưa ra dự đoán xác suất rõ ràng.

Hệ số nhiệt độ (Temperature Scaling) là một kỹ thuật điều chỉnh phân phối xác suất đầu ra của softmax nhằm kiểm soát mức độ sắc nét hoặc làm mượt (smoothing) của phân phối. Cụ thể, các logits được chia cho một tham số nhiệt độ $\tau > 0$ trước khi áp dụng softmax:

$$p_i^{(\tau)} = \frac{e^{z_i/\tau}}{\sum_{j=1}^K e^{z_j/\tau}}. \quad (2.2)$$

Khi $\tau = 1$, hàm softmax cho ra phân phối chuẩn. Với $\tau > 1$, phân phối xác suất trở nên mượt hơn, các lớp có xác suất gần nhau hơn, phản ánh mức độ bất định cao hơn của mô hình. Ngược lại, khi $\tau < 1$, phân phối trở nên sắc nét, xác suất tập trung mạnh vào các lớp có logit lớn.

Kỹ thuật temperature scaling đóng vai trò quan trọng trong bài toán chắt lọc tri thức (knowledge distillation), giúp làm lộ ra các mối quan hệ tiềm ẩn giữa các lớp mà mô hình giáo viên đã học được, từ đó hỗ trợ mô hình học sinh tiếp thu tri thức hiệu quả hơn.


2.3 Hàm mất mát chất lọc tri thức (Knowledge Distillation Loss)

Trong khuôn khổ chất lọc tri thức, hàm mất mát thường được xây dựng như sự kết hợp giữa hai thành phần: (i) hàm mất mát cross-entropy giữa dự đoán của mô hình học sinh với nhãn thực, và (ii) hàm mất mát cross-entropy (hoặc KL divergence) giữa các phân phối xác suất mềm của mô hình giáo viên và mô hình học sinh.

Cụ thể, hàm mất mát tổng quát được biểu diễn như sau:

$$\mathcal{L}(x; W) = \alpha H(y, \sigma(z_s; 1)) + \beta H(\sigma(z_t; \tau), \sigma(z_s; \tau)), \quad (2.3)$$

trong đó z_t và z_s lần lượt là logits của mô hình giáo viên và mô hình học sinh, $\sigma(\cdot; \tau)$ là hàm softmax với hệ số nhiệt độ τ , y là nhãn thực, $H(\cdot, \cdot)$ là hàm cross-entropy, và α, β là các hệ số cân bằng.



Hình 2.2: Kiến trúc học chất lọc tri thức giữa mô hình giáo viên và mô hình học sinh

Cách kết hợp này cho phép mô hình học sinh vừa học theo nhãn thực (hard label), vừa tận dụng thông tin phân phối xác suất mềm do mô hình giáo viên cung cấp. Tuy nhiên, trong nhiều trường hợp, phân phối đầu ra của mô hình giáo viên thường rất sắc nét, với xác suất cao tập trung vào một lớp duy nhất, dẫn đến việc truyền tải tri thức bị hạn chế.

Do đó, hệ số nhiệt độ được sử dụng nhằm làm mềm phân phối xác suất, giúp bộc lộ các mối quan hệ giữa các lớp còn lại (còn gọi là *dark knowledge*). Khi tăng giá trị τ , phân phối xác suất trở nên đều hơn, từ đó giúp mô hình học sinh khai thác thêm thông tin hữu ích vượt ra ngoài nhãn gốc.

Trong trường hợp huấn luyện độc lập, mô hình học sinh chỉ sử dụng hàm mất mát cross-entropy tiêu chuẩn với $\tau = 1$. Các dự đoán trong tình huống này được gọi là dự đoán cứng (hard prediction), do không áp dụng kỹ thuật làm mềm phân phối xác suất.

2.4 Vận tải tối ưu (Optimal Transport) và Khoảng cách Wasserstein (Wasserstein Distance)

Vận tải tối ưu (Optimal Transport – OT) [9] là một khuôn khổ lý thuyết toán học nhằm mô tả quá trình biến đổi một phân phối xác suất ban đầu sang một phân phối xác suất đích sao cho chi phí tổng thể của quá trình dịch chuyển là nhỏ nhất. Chi phí này thường được xác định dựa trên khoảng cách hình học giữa các điểm trong không gian. Bài toán OT có nguồn gốc từ công trình của Monge vào cuối thế kỷ XVIII và hiện nay đã trở thành một công cụ nền tảng trong nhiều lĩnh vực như xác suất, thống kê, học máy và thị giác máy tính.

Xét hai phân phối xác suất μ và ν được xác định trên cùng một không gian $\mathcal{X}$. Bài toán optimal transport [9] tìm một kế hoạch vận chuyển phù hợp để chuyển khối lượng từ μ sang ν với tổng chi phí nhỏ nhất. Gọi $c(x, y)$ là chi phí cần thiết để vận chuyển một đơn vị khối lượng từ vị trí x đến vị trí y , bài toán OT có thể được biểu diễn thông qua việc tìm một phân phối chung γ trên không gian tích $\mathcal{X} \times \mathcal{X}$, sao cho các phân phối biên của γ lần lượt là μ và ν , đồng thời cực tiểu hóa hàm chi phí:

$$\min_{\gamma \in \Pi(\mu, \nu)} \int_{\mathcal{X} \times \mathcal{X}} c(x, y) d\gamma(x, y),$$

trong đó $\Pi(\mu, \nu)$ là tập tất cả các phân phối chung có phân phối biên tương ứng với μ và ν .

Dựa trên khuôn khổ của optimal transport [9], khoảng cách Wasserstein [10] (còn được gọi là earth mover's distance) được xây dựng như một độ đo để định lượng mức độ khác biệt giữa hai phân phối xác suất. Cụ thể, khoảng cách Wasserstein bậc p giữa hai phân phối μ và ν được định nghĩa bởi:

$$W_p(\mu, \nu) = \left(\min_{\gamma \in \Pi(\mu, \nu)} \int_{\mathcal{X} \times \mathcal{X}} d(x, y)^p d\gamma(x, y) \right)^{1/p},$$

trong đó $d(x, y)$ là hàm khoảng cách trên không gian $\mathcal{X}$, thường được lựa chọn là khoảng cách Euclid.

Một trong những ưu điểm quan trọng của khoảng cách Wasserstein [10] là khả năng phản ánh trực tiếp cấu trúc hình học của không gian dữ liệu, cho phép đo lường sự khác biệt thực sự về vị trí giữa các khối lượng xác suất. Nhờ đặc tính này, Wasserstein distance được ứng dụng rộng rãi trong nhiều bài toán học máy, bao gồm so khớp phân phối, mô hình sinh dữ liệu và chất lọc tri thức, nơi việc đánh giá sự tương đồng giữa các phân phối đóng vai trò then chốt.

Trong các bài toán thực tế, đặc biệt là trong xử lý ngôn ngữ tự nhiên, các phân

phối thường có dạng rời rạc. Khi đó, xét hai phân phối rời rạc $p = (p_1, \dots, p_m)$ và $q = (q_1, \dots, q_n)$ được xác định trên các tập điểm hữu hạn $\{x_1, \dots, x_m\}$ và $\{y_1, \dots, y_n\}$. Khoảng cách Wasserstein bậc nhất giữa p và q có thể được tính thông qua bài toán tối ưu:

$$W_1(p, q) = \min_{P \in \Pi(p, q)} \sum_{i=1}^m \sum_{j=1}^n P_{ij} C_{ij},$$

trong đó P là ma trận kế hoạch vận chuyển thỏa mãn các ràng buộc về phân phối biên, với $P_{ij} \geq 0$, và C_{ij} biểu diễn chi phí vận chuyển giữa hai điểm x_i và y_j .

Một vấn đề quan trọng trong các bài toán căn chỉnh biểu diễn là lựa chọn độ đo phù hợp để so sánh giữa các không gian đặc trưng. Các độ đo đơn giản như cosine similarity thường được sử dụng rộng rãi do tính toán hiệu quả và khả năng phản ánh quan hệ hình học cục bộ giữa hai vector. Tuy nhiên, cosine similarity chỉ đo mức độ tương đồng giữa từng cặp vector riêng lẻ và không xét đến cấu trúc phân phối xác suất tổng thể của dữ liệu.

Trong bối cảnh chất lọc tri thức giữa các mô hình ngôn ngữ lớn, đặc biệt khi hai mô hình sử dụng tokenizer khác nhau, các biểu diễn thường tồn tại dưới dạng các phân phối rời rạc có kích thước và cấu trúc không đồng nhất. Khi đó, một token của mô hình này có thể tương ứng với nhiều token của mô hình còn lại, dẫn đến các mối quan hệ nhiều-đến-nhiều mà các độ đo cục bộ như cosine similarity không thể mô hình hóa một cách tự nhiên.

Optimal Transport khắc phục hạn chế này bằng cách xem mỗi tập biểu diễn như một phân phối xác suất và tìm một kế hoạch vận chuyển tối ưu trên toàn bộ phân phối. Nhờ tối ưu hóa chi phí tổng thể thay vì từng cặp điểm độc lập, OT cho phép khai thác đồng thời thông tin hình học và cấu trúc phân bố toàn cục của không gian nhúng. Do đó, khoảng cách Wasserstein dựa trên Optimal Transport trở thành một công cụ phù hợp và hiệu quả cho các bài toán căn chỉnh phân phối và chất lọc tri thức trong các thiết lập có sự khác biệt về kiến trúc hoặc tokenizer.

2.5 Ngữ cảnh của bài toán

Bài toán chất lọc tri thức (knowledge distillation) trong xử lý ngôn ngữ tự nhiên có thể mô tả như sau:

- **Đầu vào:**

- Bộ dữ liệu huấn luyện $D = \{(x^i, y^i)\}_{i=1}^n$, trong đó x^i là chuỗi văn bản đầu vào và y^i là chuỗi nhãn hoặc văn bản mục tiêu dưới dạng token.
- Mô hình giáo viên f_T bao gồm L_T lớp với chiều ẩn d_T , ma trận từ vựng

V_T , ký hiệu ma trận nhúng $E_T \in \mathbb{R}^{|V_T| \times d_T}$ và trạng thái ẩn $H^T \in \mathbb{R}^{M \times d_T}$.

- Mô hình học sinh f_S bao gồm L_S lớp với chiều ẩn d_S , ma trận từ vựng V_S , ký hiệu ma trận nhúng $E_S \in \mathbb{R}^{|V_S| \times d_S}$ và trạng thái ẩn $H^S \in \mathbb{R}^{N \times d_S}$.

• **Quy trình:**

- Với mỗi x , mô hình giáo viên mã hóa thành $[x_1^T, x_2^T, \dots, x_M^T]$, mô hình học sinh mã hóa thành $[x_1^S, x_2^S, \dots, x_N^S]$, có thể $M \neq N$ do sử dụng tokenizer khác nhau.

- **Đầu ra:** Mô hình học sinh f_S sau huấn luyện, kích thước nhỏ hơn mô hình giáo viên nhưng vẫn giữ hiệu năng tốt trên các nhiệm vụ xử lý ngôn ngữ.

Các phương pháp chất lọc tri thức (knowledge distillation) chủ yếu tập trung căn chỉnh xác suất đầu ra và/hoặc trạng thái ẩn giữa hai mô hình. Đặc biệt, khi giáo viên và học sinh dùng tokenizer khác nhau, quá trình căn chỉnh càng phức tạp do lệch số lượng token và không gian biểu diễn. Do đó, nghiên cứu giải pháp căn chỉnh hiệu quả trong trường hợp bất đồng tokenizer, kiến trúc hoặc từ vựng là một hướng quan trọng nhằm nâng cao chất lượng chất lọc.

2.6 Các kết quả nghiên cứu tương tự

Các phương pháp chất lọc tri thức cho mô hình ngôn ngữ lớn hiện nay chủ yếu được phân loại dựa trên mức độ truy cập vào thông tin nội bộ của mô hình giáo viên, trong đó nổi bật là hướng tiếp cận hộp trắng (white-box) và hộp đen (black-box).

Đối với hướng hộp trắng, mô hình học sinh được huấn luyện không chỉ dựa trên đầu ra cuối cùng của mô hình giáo viên mà còn khai thác các biểu diễn trung gian bên trong, bao gồm các tầng ẩn, tầng chú ý hoặc các đặc trưng nội bộ khác. Việc sử dụng trực tiếp các biểu diễn ẩn cho phép mô hình học sinh tiếp thu sâu hơn cấu trúc biểu diễn và tri thức ngữ nghĩa mà mô hình giáo viên đã học được, từ đó giúp cải thiện khả năng tổng quát hóa và hiệu quả huấn luyện. Do đó, các phương pháp hộp trắng thường được đánh giá là có tiềm năng truyền tải tri thức phong phú và hiệu quả hơn, đặc biệt trong bối cảnh các mô hình ngôn ngữ lớn có cấu trúc nhiều tầng và biểu diễn phức tạp.

Ngược lại, các phương pháp hộp đen chỉ sử dụng thông tin đầu ra của mô hình giáo viên, thường là các logit hoặc phân phối xác suất dự đoán, để hướng dẫn quá trình huấn luyện mô hình học sinh thông qua các hàm mất mát như Kullback–Leibler divergence. Mặc dù có ưu điểm về tính đơn giản và không yêu cầu truy cập vào kiến trúc nội bộ của mô hình giáo viên, các phương pháp này thường gặp hạn chế trong việc truyền tải các đặc trưng sâu về ngữ nghĩa và cấu

trúc biểu diễn. Ngoài ra, phần lớn các phương pháp hộp đen còn giả định rằng mô hình giáo viên và mô hình học sinh sử dụng chung tokenizer hoặc không gian đầu ra tương đồng, điều này làm giảm tính linh hoạt khi áp dụng cho các mô hình ngôn ngữ lớn hiện đại với tokenizer và kiến trúc đa dạng.

Xuất phát từ thực tế đó, nhiều nghiên cứu gần đây đã tập trung mở rộng các phương pháp chất lọc tri thức theo hướng hộp trắng, đồng thời tìm cách xử lý các thách thức phát sinh khi mô hình giáo viên và mô hình học sinh khác biệt về tokenizer, độ sâu mạng hoặc kích thước không gian biểu diễn. Các hướng tiếp cận này cho thấy việc khai thác hiệu quả các biểu diễn ẩn, kết hợp với cơ chế căn chỉnh linh hoạt giữa các mô hình khác biệt, là một hướng nghiên cứu tiềm năng và phù hợp với yêu cầu thực tiễn của chất lọc tri thức cho mô hình ngôn ngữ lớn.

2.6.1 Phương pháp MultiOT (Multi-Level Optimal Transport)

MultiOT [1] là một phương pháp chất lọc tri thức tiên tiến được đề xuất cho các mô hình ngôn ngữ lớn, đặc biệt phù hợp trong bối cảnh mô hình giáo viên và mô hình học sinh sử dụng các bộ tokenizer khác nhau. Thay vì thực hiện căn chỉnh độc lập trên từng token như nhiều phương pháp truyền thống, MultiOT khai thác vận chuyển tối ưu đa cấp (multi-level optimal transport) để đồng thời căn chỉnh các phân phối đầu ra của hai mô hình trên toàn bộ chuỗi sinh.

Bài toán tổng quát. Xét một mẫu huấn luyện với đầu vào x và nhãn đúng tương ứng y . Gọi f_T và f_S lần lượt là mô hình giáo viên và mô hình học sinh. Đầu ra logits sau khi áp dụng hàm softmax với tham số nhiệt độ τ của hai mô hình được ký hiệu lần lượt là $t \in \mathbb{R}^{T \times m}$ và $s \in \mathbb{R}^{T \times n}$:

$$t = \sigma_\tau(f_T(x)), \quad s = \sigma_\tau(f_S(x)), \quad (2.4)$$

trong đó m và n lần lượt biểu thị kích thước từ vựng đầu ra của mô hình giáo viên và mô hình học sinh, còn T là số lượng token trong chuỗi sinh. Với mỗi vị trí token t , các phần tử $t_i(t)$ và $s_i(t)$ lần lượt biểu diễn giá trị tại chiều thứ i của logits giáo viên và học sinh tại vị trí đó.

Các thành phần hàm mất mát. Nhằm đảm bảo quá trình chất lọc tri thức diễn ra đầy đủ ở cả mức token và mức chuỗi, MultiOT xây dựng hàm mất mát tổng hợp bao gồm ba thành phần chính:

- **Holistic Absolute Difference Loss (L_{HAD}):** Thành phần này đo tổng sai khác tuyệt đối giữa các logits đã được sắp xếp (ranking) của mô hình giáo viên và

mô hình học sinh tại từng vị trí token:

$$L_{HAD} = \sum_{t=1}^T \sum_{i=1}^k |t_i^k(t) - s_i^k(t)|. \quad (2.5)$$

- **Sequential Logarithmic Loss (L_{SL}):** Thành phần này khuyến khích mô hình học sinh phân bố xác suất đầu ra tương đồng với mô hình giáo viên thông qua hàm logarit:

$$L_{SL} = - \sum_{t=1}^T \sum_{i=1}^k t_i^k(t) \log s_i^k(t). \quad (2.6)$$

- **Sinkhorn Distance Loss (L_{SD}):** Để đo sự khác biệt ở mức toàn chuỗi, MultiOT sử dụng khoảng cách Sinkhorn, là dạng chính quy hóa entropy của vận chuyển tối ưu, giúp bài toán hội tụ ổn định và giảm chi phí tính toán:

$$L_{SD} = \langle P_\lambda, C \rangle, \quad (2.7)$$

trong đó P_λ là ma trận vận chuyển tối ưu thu được thông qua thuật toán Sinkhorn.

Hàm mất mát tổng thể. Từ các thành phần trên, hàm mất mát cuối cùng của MultiOT được xây dựng bằng cách kết hợp hàm cross-entropy chuẩn với các thành phần chất lọc:

$$L = \sum_{t=1}^T L_{CE}(y(t), s(t)) + \alpha (L_{HAD} + \beta L_{SL} + \gamma L_{SD}), \quad (2.8)$$

trong đó L_{CE} là hàm mất mát cross-entropy, còn α , β và γ là các hệ số siêu tham số điều chỉnh mức đóng góp của từng thành phần.

Nhận xét. Nhờ cơ chế vận chuyển tối ưu đa cấp, MultiOT cho phép mô hình học sinh học hiệu quả từ mô hình giáo viên cả ở mức token lẫn mức toàn chuỗi, ngay cả khi hai mô hình sử dụng tokenizer khác nhau. Phương pháp này không chỉ giúp mô hình học sinh bắt chước các xác suất đầu ra riêng lẻ mà còn bảo toàn được cấu trúc tổng thể của phân phối xác suất, qua đó cải thiện khả năng tổng quát hóa và hiệu quả trên các bài toán sinh văn bản.

2.6.2 Phương pháp DSKD (Dual-Space Knowledge Distillation)

Nhằm khắc phục những hạn chế của các phương pháp chất lọc tri thức truyền thống, đặc biệt là sự khác biệt về không gian đầu ra và yêu cầu sử dụng chung bộ từ vựng giữa mô hình giáo viên và mô hình học sinh, phương pháp Dual-Space

Knowledge Distillation (DSKD) [2] đã được đề xuất gần đây. DSKD xây dựng một khung chặt lọc tri thức hai không gian (dual-space), cho phép thực hiện chặt lọc tri thức hiệu quả giữa các mô hình ngôn ngữ lớn có kiến trúc hoặc tokenizer không đồng nhất.

Ý tưởng cốt lõi của DSKD [2] là thống nhất không gian biểu diễn đầu ra của hai mô hình bằng cách sử dụng các phép chiếu (projection) để ánh xạ trạng thái ẩn (hidden states) của mỗi mô hình sang không gian biểu diễn của mô hình còn lại. Nhờ đó, các phân phối xác suất đầu ra có thể được so sánh trực tiếp hoặc sử dụng chung đầu dự đoán (prediction head), bất chấp sự khác biệt về kiến trúc hay từ vựng.

Chặt lọc tri thức trong không gian học sinh (Student Space).

Trong không gian của mô hình học sinh, DSKD sử dụng một lớp chiếu tuyến tính $P^{t \rightarrow s}$ để ánh xạ chuỗi trạng thái ẩn cuối cùng của mô hình giáo viên sang không gian biểu diễn của học sinh:

$$h_{1:n}^{t \rightarrow s} = P^{t \rightarrow s}(h_{1:n}^t; \theta_P^{t \rightarrow s}) \in \mathbb{R}^{n \times d}, \quad (2.9)$$

trong đó $h_{1:n}^t$ là chuỗi trạng thái ẩn của mô hình giáo viên, d là kích thước không gian ẩn của mô hình học sinh, và $\theta_P^{t \rightarrow s}$ là tập tham số của lớp chiếu. Phân phối xác suất tương ứng được tính thông qua đầu dự đoán của học sinh:

$$p_{1:n}^{t \rightarrow s} = \text{softmax}(h_{1:n}^{t \rightarrow s} W^s) \in \mathbb{R}^{n \times |V|}, \quad (2.10)$$

với W^s là ma trận tham số của prediction head học sinh và $|V|$ là kích thước từ vựng. Hàm mất mát cross-entropy được áp dụng lên phân phối này:

$$L_{t \rightarrow s}^{ce} = - \sum_i \log(p_{1:n}^{t \rightarrow s}(x_i^* | x_{<i})). \quad (2.11)$$

Bên cạnh đó, phân phối $p_{1:n}^{t \rightarrow s}$ còn được xem như một phân phối giáo viên trung gian để tính hàm mất mát chặt lọc tri thức trong không gian học sinh:

$$L_{stu}^{kd} = \sum_i D(p_{1:n}^{t \rightarrow s}(x_i | x_{<i}; \tau) \parallel q_\theta(x_i | x_{<i}; \tau)), \quad (2.12)$$

trong đó $D(\cdot \parallel \cdot)$ là hàm đo khoảng cách (chẳng hạn KL divergence) và τ là tham số nhiệt độ.

Chặt lọc tri thức trong không gian giáo viên (Teacher Space).

Tương tự, DSKD tiếp tục thực hiện chất lọc tri thức trong không gian của mô hình giáo viên thông qua một lớp chiếu khác $P_{s \rightarrow t}$, dùng để ánh xạ trạng thái ẩn của mô hình học sinh sang không gian giáo viên:

$$h_{s \rightarrow t} = P_{s \rightarrow t}(h_{1:n}^s; \theta_{s \rightarrow t}) \in \mathbb{R}^{n \times D}, \quad (2.13)$$

với D là kích thước không gian ẩn của mô hình giáo viên. Phân phối xác suất tương ứng được tính bằng prediction head của giáo viên:

$$q_{s \rightarrow t} = \text{softmax}(h_{s \rightarrow t} W_t) \in \mathbb{R}^{n \times |V|}. \quad (2.14)$$

Hàm mất mát chất lọc tri thức trong không gian giáo viên được xác định như sau:

$$L_{tea}^{kd} = \sum_i \text{KL}(p(x_i | x_{<i}; \tau) \parallel q_{s \rightarrow t}(x_i | x_{<i}; \tau)). \quad (2.15)$$

Hàm mất mát tổng thể. Tổng hợp lại, hàm mất mát cuối cùng của phương pháp DSKD được xây dựng từ ba thành phần:

$$L_{DSKD} = L_{stu}^{kd} + L_{tea}^{kd} + L_{t \rightarrow s}^{ce}. \quad (2.16)$$


Căn chỉnh token với cơ chế chú ý chéo (Cross-Model Attention). Để mở rộng khả năng áp dụng trong trường hợp mô hình giáo viên và mô hình học sinh sử dụng tokenizer khác nhau, DSKD còn đề xuất cơ chế chú ý chéo giữa các mô hình (Cross-Model Attention – CMA). Cơ chế này học một ma trận chú ý giữa embedding của giáo viên và học sinh nhằm tự động căn chỉnh các token tương ứng trong hai chuỗi. Các biểu diễn ẩn sau khi căn chỉnh được sử dụng để tiếp tục áp dụng quy trình chất lọc tri thức hai không gian như đã trình bày.

Nhìn chung, DSKD là một phương pháp tiêu biểu cho phép thực hiện chất lọc tri thức hiệu quả giữa các mô hình ngôn ngữ lớn có kiến trúc và tokenizer khác nhau, qua đó khắc phục những hạn chế cốt lõi của các phương pháp chất lọc tri thức truyền thống.

2.6.3 Phương pháp RAIL-KD (Random Intermediate Layer Knowledge Distillation)

Chất lọc tri thức tại các tầng trung gian có thể cải thiện kỹ thuật KD chuẩn (vốn chỉ nhắm tới đầu ra của mô hình giáo viên và mô hình học sinh), đặc biệt trong bối cảnh các mô hình ngôn ngữ lớn được huấn luyện sẵn. Tuy nhiên, chất lọc tại tầng trung gian phải đối mặt với gánh nặng tính toán lớn và đòi hỏi nhiều công sức kỹ

thuật để thiết lập được một ánh xạ tầng phù hợp. Để giải quyết các vấn đề này, các tác giả đề xuất phương pháp Random Intermediate Layer Knowledge Distillation (RAIL-KD)[3], trong đó các tầng trung gian từ mô hình giáo viên được chọn ngẫu nhiên để chắt lọc sang các tầng trung gian của mô hình học sinh. Hình 2.3 minh họa quy trình chắt lọc tầng trung gian của phương pháp RAIL-KD.



Hình 2.3: Phương pháp RAIL-KD[3]

Giả sử một mẫu huấn luyện được ký hiệu là (X, y) , trong đó $X = (x_0, \dots, x_{L-1})$ là chuỗi gồm L token và y là nhãn tương ứng. Trong Hình 2.3, RAIL-KD áp dụng phép *Random Selection* lên các tầng trung gian của mô hình giáo viên để ngẫu nhiên chọn m trong số n tầng.

Biểu diễn tầng trung gian của m tầng được chọn của mô hình giáo viên và mô hình học sinh khi xử lý đầu vào X lần lượt được ký hiệu là:

$$H_X^T = \{H_{1,X}^T, \dots, H_{m,X}^T\}, \quad H_X^{S_\theta} = \{H_{1,X}^{S_\theta}, \dots, H_{m,X}^{S_\theta}\},$$

trong đó

$$H_{i,X}^T = \bigcup_{k=0}^{L-1} \{h_{i,x_k}^T\} \in \mathbb{R}^{L \times d_1}, \quad H_{i,X}^{S_\theta} = \bigcup_{k=0}^{L-1} \{h_{i,x_k}^{S_\theta}\} \in \mathbb{R}^{L \times d_2}.$$

Tại đây, d_1 và d_2 lần lượt là kích thước ẩn của tầng trong mô hình giáo viên và mô hình học sinh. Để thu được $H_{i,X}^T$ và $H_{i,X}^{S_\theta}$, ta cần lấy biểu diễn của từng token x_k tại mỗi tầng i , được ký hiệu lần lượt là h_{i,x_k}^T và $h_{i,x_k}^{S_\theta}$.

Tính biểu diễn tổng hợp theo tầng. Ở bước này, RAIL-KD cần thu được biểu

diễn tổng hợp của chuỗi X tại mỗi tầng. Có hai lựa chọn phổ biến: dùng biểu diễn token hoặc dùng phép *mean-pooling* trên các biểu diễn token của tầng. RAIL-KD sử dụng phép trung bình theo hàng của $H_{i,X}^T$ và $H_{i,X}^{S_\theta}$ để thu được:

$$\bar{h}_{i,X}^T \in \mathbb{R}^{d_1}, \quad \bar{h}_{i,X}^{S_\theta} \in \mathbb{R}^{d_2},$$

với:

$$\bar{h}_{i,X}^T = \frac{1}{L} \sum_{k=0}^{L-1} h_{i,x_k}^T, \quad \bar{h}_{i,X}^{S_\theta} = \frac{1}{L} \sum_{k=0}^{L-1} h_{i,x_k}^{S_\theta}. \quad (1)$$

Sau khi thu được các biểu diễn tầng tổng hợp cho mô hình giáo viên và học sinh, RAIL-KD thực hiện chọn ngẫu nhiên m tầng từ mô hình giáo viên trong quá trình huấn luyện để tiến hành *chắt lọc tầng trung gian* (ILD). RAIL-KD cung cấp hai dạng ILD: *chắt lọc theo từng tầng* (Hình 2.3(a)) và *chắt lọc dựa trên biểu diễn ghép tầng* (Hình 2.3(b)), được mô tả như sau.

Layer-wise RAIL-KD Trong thiết lập này, các biểu diễn tầng $\bar{h}_{i,X}^T \in \mathbb{R}^{d_1}$ và $\bar{h}_{i,X}^{S_\theta} \in \mathbb{R}^{d_2}$ được chiếu vào cùng một không gian có kích thước u :

$$\hat{h}_{i,X}^T, \hat{h}_{i,X}^{S_\theta} \in \mathbb{R}^u,$$

thông qua hai ánh xạ tuyến tính có kích thước lần lượt là $(d_1 \times u)$ và $(d_2 \times u)$.

Giả sử tập $A = \{a_\kappa \mid a_\kappa \in \{1, 2, \dots, n\}, 1 \leq \kappa \leq m\}$ chứa chỉ số của m tầng được chọn từ giáo viên, thì hàm mất mát layer-wise được định nghĩa như sau:

$$\mathcal{L}_{\text{RAIL-KD}}^l = \sum_{X \in \mathcal{X}} \sum_{i \in A} \alpha_i \left\| \frac{\hat{h}_{i,X}^T}{\|\hat{h}_{i,X}^T\|_2} - \frac{\hat{h}_{i,X}^{S_\theta}}{\|\hat{h}_{i,X}^{S_\theta}\|_2} \right\|_2^2, \quad (2)$$

trong đó α_i là hệ số trọng số, và trong các thực nghiệm tác giả đặt $\alpha_i = 1$.

Concatenated RAIL-KD Trong thiết lập này, các biểu diễn tầng được ghép nối:

$$\bar{h}_X^T = [\bar{h}_{i,X}^T]_{i \in A}, \quad \bar{h}_X^{S_\theta} = [\bar{h}_{j,X}^{S_\theta}]_{j=1}^m.$$

Các biểu diễn ghép nối này được chiếu vào cùng một không gian u thông qua ánh xạ tuyến tính có kích thước $(md_1 \times u)$ và $(md_2 \times u)$ để thu được:

$$\hat{h}_X^T, \hat{h}_X^{S_\theta} \in \mathbb{R}^u.$$

Hàm mất mát dạng ghép tầng được định nghĩa:

$$\mathcal{L}_{\text{RAIL-KD}}^c = \sum_{X \in \mathcal{X}} \left\| \frac{\hat{h}_X^T}{\|\hat{h}_X^T\|_2} - \frac{\hat{h}_X^{S_\theta}}{\|\hat{h}_X^{S_\theta}\|_2} \right\|_2^2. \quad (3)$$

Kết luận. RAIL-KD cho thấy hiệu quả rõ rệt trong việc tận dụng thông tin từ nhiều tầng trung gian của mô hình giáo viên, nhờ cơ chế chọn ngẫu nhiên tầng kết hợp với hai dạng lan truyền tri thức: (i) chất lọc theo từng tầng và (ii) chất lọc dựa trên biểu diễn ghép tầng. Cách tiếp cận này giúp mô hình học sinh học được cấu trúc biểu diễn đa tầng, giảm hiện tượng phụ thuộc vào một tầng duy nhất và cải thiện khả năng tổng quát hoá.

Tuy nhiên, phương pháp vẫn tồn tại một số hạn chế. Thứ nhất, việc chọn tầng hoàn toàn ngẫu nhiên làm cho quá trình học không đảm bảo tận dụng được các tầng quan trọng nhất của mô hình giáo viên; một số tầng giàu thông tin có thể bị chọn quá ít, trong khi các tầng ít hữu ích lại được chọn nhiều lần. Thứ hai, RAIL-KD coi các tầng được chọn là độc lập và đóng góp như nhau, bỏ qua mức độ quan trọng không đồng đều giữa các tầng. Do đó, mô hình học sinh không được hướng dẫn tối ưu để ưu tiên học từ những tầng có độ đóng góp lớn hơn đối với hiệu năng đầu ra. Trong chương này, đồ án đã trình bày tổng quan về mô hình ngôn ngữ lớn (Large Language Models – LLMs) và nhắc lại các cơ chế hoạt động cơ bản của kiến trúc Transformer. Bên cạnh đó, các kiến thức nền tảng liên quan đến lý thuyết vận chuyển tối ưu (Optimal Transport [9]) và khoảng cách Wasserstein [10] cũng được giới thiệu, làm cơ sở cho các phương pháp chất lọc tri thức hiện đại.

Chương này cũng tổng hợp và phân tích một số phương pháp chất lọc tri thức tiêu biểu như MultiOT, DSKD và RAILKD. Các phương pháp này cho thấy hiệu quả trong việc truyền tải tri thức giữa các mô hình ngôn ngữ lớn, đặc biệt trong bối cảnh khác biệt về kiến trúc hoặc không gian biểu diễn. Tuy nhiên, nhiều phương pháp dựa trên Optimal Transport hiện nay thường chỉ sử dụng một hàm chi phí duy nhất để căn chỉnh các phân phối giữa mô hình giáo viên và mô hình học sinh, điều này có thể chưa phản ánh đầy đủ sự đa dạng trong biểu diễn tri thức của các mô hình.

Ngoài ra, mặc dù một số nghiên cứu đã đề xuất việc sử dụng nhiều ma trận chi phí khác nhau, nhưng vẫn còn thiếu các cơ chế tích hợp hiệu quả nhằm khai thác đồng thời các nguồn thông tin này, đặc biệt khi không gian biểu diễn giữa các mô hình có sự khác biệt đáng kể. Những hạn chế trên chính là động lực cho hướng tiếp cận được đề xuất trong chương tiếp theo của đồ án.

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT

Chương này trình bày phương pháp huấn luyện cho bài toán chất lọc tri thức, khai thác các không gian biểu diễn khác nhau của mô hình ngôn ngữ lớn. Phương pháp này không chỉ giúp mô hình học sinh bắt chước đầu ra của mô hình giáo viên, mà còn học được các biểu diễn ngữ nghĩa từ các tầng ẩn của mô hình giáo viên.

3.1 Tổng quan giải pháp

Khác với các phương pháp chất lọc truyền thống thường giả định mô hình giáo viên và mô hình học sinh sử dụng cùng tokenizer và có kiến trúc tương đồng, bài toán trong đề án này được đặt ra trong một bối cảnh thực tiễn hơn, nơi các mô hình có thể được huấn luyện độc lập với các bộ mã hóa khác nhau và có độ sâu kiến trúc không đồng nhất. Trong trường hợp này, các phương pháp căn chỉnh trực tiếp theo token hoặc theo tầng cố định thường không còn phù hợp, bởi không tồn tại ánh xạ một-một rõ ràng giữa các token cũng như giữa các tầng của hai mô hình.

Xuất phát từ quan sát trên, phương pháp đề xuất được thiết kế theo hướng căn chỉnh mềm (*soft alignment*) ở nhiều cấp độ, cho phép mô hình học sinh linh hoạt tiếp nhận tri thức từ mô hình giáo viên thông qua các trọng số học được, thay vì áp đặt các ánh xạ cứng nhắc. Cách tiếp cận này giúp giảm thiểu sai lệch do sự khác biệt giữa các tokenizer, đồng thời tận dụng hiệu quả các biểu diễn mang tính ngữ nghĩa cao tại những tầng quan trọng của mô hình giáo viên.


Phương pháp đề xuất thực hiện quá trình truyền tri thức từ mô hình giáo viên sang mô hình học sinh trong bối cảnh tồn tại hai thách thức chính trong thực tiễn: (i) sự không tương thích giữa các tokenizer và (ii) sự khác biệt về độ sâu kiến trúc giữa hai mô hình.

Để giải quyết vấn đề không tương thích tokenizer, một phép chiếu từ vệt được xây dựng dựa trên các token trùng nhau giữa hai mô hình, đóng vai trò như các điểm neo hình học trong không gian nhúng. Trên cơ sở đó, cơ chế căn chỉnh theo mức độ span có trọng số được sử dụng, cho phép thiết lập mối liên hệ mềm giữa các token được sinh ra bởi hai cơ chế tách token khác nhau của mô hình giáo viên và mô hình học sinh.

Đối với thách thức về sự khác biệt độ sâu mô hình, đề án đề xuất một chiến lược truyền tri thức có nhận thức tầm quan trọng của tầng, trong đó các lớp của mô hình giáo viên được xếp hạng theo mức độ đóng góp vào quá trình biến đổi biểu diễn. Tri thức sau đó được chất lọc thông qua cơ chế căn chỉnh có trọng số, giúp mô hình học sinh tập trung học từ những biểu diễn mang nhiều thông tin hữu ích nhất, đồng

thời hạn chế ảnh hưởng của các tầng dư thừa hoặc kém quan trọng.

Bằng cách kết hợp hai thành phần trên, phương pháp đề xuất bảo đảm quá trình truyền tri thức hiệu quả giữa các mô hình có sự khác biệt cả về tokenizer lẫn độ sâu kiến trúc. Quy trình tổng thể của phương pháp được minh họa trong Hình 3.1.



Hình 3.1: Quy trình tổng thể của phương pháp đề xuất

3.2 Nhắc lại quy ước

Để thuận tiện cho việc trình bày phương pháp đề xuất và giúp người đọc dễ nắm bắt nội dung, phần này nhắc lại một số định nghĩa và ký hiệu được sử dụng trong đồ án.

Giả sử ta có một tập huấn luyện $D = \{(x^i, y^i)\}_{i=1}^n$, trong đó mỗi câu đầu vào x được mã hóa bởi mô hình giáo viên và mô hình học sinh, tạo thành các chuỗi token lần lượt là $[x_1^T, x_2^T, \dots, x_M^T]$ và $[x_1^S, x_2^S, \dots, x_N^S]$.

Do khác biệt của bộ mã hóa, độ dài hai chuỗi có thể khác nhau ($M \neq N$), dẫn đến sự không tương thích trong quá trình truyền tri thức. Mô hình giáo viên f_T bao gồm L_T lớp với kích thước ẩn d_T và tập từ vựng V_T , trong khi mô hình học sinh f_S có L_S lớp, kích thước ẩn d_S và tập từ vựng V_S .

Các ma trận nhúng của hai mô hình lần lượt được ký hiệu là $E_T \in \mathbb{R}^{|V_T| \times d_T}$ và $E_S \in \mathbb{R}^{|V_S| \times d_S}$. Các trạng thái ẩn được biểu diễn bởi $H^T \in \mathbb{R}^{M \times d_T}$ đối với mô hình giáo viên và $H^S \in \mathbb{R}^{N \times d_S}$ đối với mô hình học sinh.

3.3 Phép chiếu từ vựng (Vocabulary Projection)

Một trong những thách thức cốt lõi trong quá trình truyền tri thức giữa các mô hình ngôn ngữ lớn là mô hình giáo viên và mô hình học sinh thường hoạt động trong các không gian biểu diễn khác nhau, thể hiện qua sự khác biệt về kích thước vector ẩn ($d_T \neq d_S$) cũng như sự không trùng khớp giữa các tập từ vựng ($V_T \neq V_S$).

Sự khác biệt này khiến việc so sánh trực tiếp hoặc căn chỉnh các biểu diễn giữa hai mô hình trở nên không khả thi nếu không có một cơ chế trung gian phù hợp.

Để giải quyết vấn đề này, một hướng tiếp cận phổ biến trong các phương pháp chất lọc trước đây là sử dụng một phép chiếu tuyến tính (*projection*) nhằm ánh xạ các vector nhúng của mô hình giáo viên sang không gian nhúng của mô hình học sinh. Phép chiếu này cho phép đưa các biểu diễn của hai mô hình về cùng một không gian, từ đó tạo điều kiện thuận lợi cho việc đo lường khoảng cách hoặc độ tương đồng giữa chúng trong quá trình huấn luyện.

Thông thường, lớp chiếu này được khởi tạo ngẫu nhiên và được huấn luyện đồng thời với các tham số của mô hình học sinh. Tuy nhiên, trong bối cảnh chất lọc giữa các mô hình có sự khác biệt lớn về tokenizer và kiến trúc, một phép chiếu được khởi tạo ngẫu nhiên có thể dẫn đến quá trình huấn luyện kém ổn định, đặc biệt trong giai đoạn đầu, khi mô hình học sinh chưa có đủ tín hiệu học để điều chỉnh không gian biểu diễn. Điều này có thể làm suy giảm đáng kể hiệu quả truyền tri thức tổng thể.

Quan sát rằng các mô hình ngôn ngữ lớn, mặc dù được huấn luyện với các tập từ vựng khác nhau, thường được xây dựng từ các kho ngữ liệu có nguồn gốc tương tự, dẫn đến sự tồn tại tự nhiên của một tập con các token trùng nhau giữa hai mô hình. Các token này thường mang ý nghĩa ngữ nghĩa ổn định và nhất quán, do đó có thể được xem như các *điểm neo* (anchors) trong không gian nhúng, đóng vai trò cầu nối giữa hai tập từ vựng khác nhau.

Dựa trên trực giác này, phương pháp tận dụng tập từ vựng chồng chéo

$$V_{\text{overlap}} = V_T \cap V_S$$

như một tập các điểm tham chiếu để huấn luyện trước ma trận chiếu từ không gian của mô hình giáo viên sang không gian của mô hình học sinh. Cụ thể, một ma trận chiếu được học:

$$W_{T \rightarrow S} \in \mathbb{R}^{d_T \times d_S}$$

nhằm tối thiểu hóa khoảng cách Euclid giữa các vector nhúng tương ứng của các token chung, sau khi đã được chuẩn hóa để loại bỏ sự khác biệt về thang đo giữa các không gian biểu diễn. Bài toán tối ưu được định nghĩa như sau:

$$\min_W \sum_{v \in V_{\text{overlap}}} \left\| E_S^{\text{overlap}}[v] - W E_T^{\text{overlap}}[v] \right\|_2^2 + \lambda \|W\|_2^2 \quad (3.1)$$

trong đó $E_T^{\text{overlap}}[v]$ và $E_S^{\text{overlap}}[v]$ lần lượt là các vector nhúng đã được chuẩn hóa của token v trong mô hình giáo viên và mô hình học sinh, còn λ là hệ số điều chuẩn nhằm tránh hiện tượng quá khớp.

Phép chiếu được huấn luyện trước theo cách này cung cấp một điểm khởi đầu ổn định và mang ý nghĩa ngữ nghĩa rõ ràng cho quá trình huấn luyện. Không chỉ giúp căn chỉnh hai không gian nhúng ở mức từ vựng, ma trận chiếu này còn đóng vai trò nền tảng cho các cơ chế căn chỉnh nâng cao hơn ở cấp độ trạng thái ẩn và token theo ngữ cảnh, sẽ được trình bày trong các mục tiếp theo.

3.4 Căn chỉnh giữa các tầng (Layer Alignment)

Bên cạnh sự không tương thích về tokenizer, một thách thức quan trọng khác trong quá trình chất lọc tri thức giữa các mô hình ngôn ngữ lớn là sự khác biệt về độ sâu kiến trúc. Trong thực tế, mô hình giáo viên thường có số tầng lớn hơn đáng kể so với mô hình học sinh, dẫn đến việc không tồn tại một ánh xạ một-một tự nhiên giữa các tầng của hai mô hình.

Các nghiên cứu gần đây về cắt tỉa mô hình (*pruning*) [11] đã chỉ ra rằng không phải tất cả các tầng trong mô hình Transformer đều đóng góp như nhau vào khả năng biểu diễn cuối cùng. Nhiều tầng có tính dư thừa cao hoặc chỉ thực hiện các biến đổi cục bộ với mức độ ảnh hưởng hạn chế đến biểu diễn ngữ nghĩa. Do đó, việc truyền tri thức từ toàn bộ các tầng của mô hình giáo viên không chỉ làm gia tăng chi phí tính toán mà còn có nguy cơ đưa nhiễu từ các tầng kém quan trọng vào quá trình huấn luyện mô hình học sinh.

Xuất phát từ quan sát này, thay vì chất lọc một cách đồng đều trên tất cả các tầng, đồ án đề xuất một chiến lược căn chỉnh giữa các tầng có nhận thức tầm quan trọng, trong đó chỉ một tập con các tầng mang nhiều thông tin nhất của mô hình giáo viên được lựa chọn để tham gia vào quá trình truyền tri thức. Cách tiếp cận này cho phép mô hình học sinh tập trung học từ những biểu diễn có giá trị ngữ nghĩa cao, đồng thời giảm thiểu ảnh hưởng của các tầng dư thừa.

Để định lượng mức độ đóng góp của từng tầng trong mô hình giáo viên, chỉ số *Block Influence (BI)* [12] được sử dụng. Cụ thể, Block Influence đối với tầng i được định nghĩa dựa trên độ tương đồng cosine giữa trạng thái ẩn đầu vào và đầu ra của tầng đó. BI càng nhỏ (tức độ tương đồng càng cao) chứng tỏ tầng này ít thay đổi biểu diễn, do đó ít đóng góp vào quá trình xử lý thông tin. Công thức tính BI được khai triển như sau:

$$BI_i = 1 - \mathbb{E}_{X,t} \left[\frac{\langle X_{i,t}, X_{i+1,t} \rangle}{\|X_{i,t}\|_2 \cdot \|X_{i+1,t}\|_2} \right],$$

trong đó $X_{i,t}$ là vector trạng thái ẩn của token thứ t tại tầng i , và phép $\langle \cdot, \cdot \rangle$ là tích vô hướng. Kỳ vọng $\mathbb{E}_{X,t}$ được tính trên toàn bộ token t . Chỉ số này phản ánh mức độ biến đổi của trạng thái ẩn đầu vào sau khi đi qua mỗi tầng, từ đó cung cấp một thước đo trực quan về ảnh hưởng của tầng đó đối với quá trình xử lý thông tin. Sau khi tính điểm BI cho toàn bộ L_T tầng của mô hình giáo viên, các tầng được sắp xếp theo thứ tự giảm dần và k tầng có điểm BI cao nhất được lựa chọn, tạo thành tập tầng quan trọng:

$$I_T = \text{TopK}(BI_{score})$$

Tuy nhiên, do sự khác biệt về độ sâu giữa hai mô hình ($L_T \neq L_S$), việc căn chỉnh trực tiếp các tầng được chọn của giáo viên sang các tầng của học sinh vẫn đặt ra thách thức. Để giải quyết vấn đề này, đề án áp dụng một phép ánh xạ theo độ sâu tương đối, cho phép gộp nhiều tầng của mô hình giáo viên vào cùng một tầng của mô hình học sinh. Cách ánh xạ này phản ánh trực giác rằng các tầng ở vị trí tương đối tương đương trong kiến trúc thường đảm nhiệm các vai trò xử lý thông tin tương tự nhau.

Tầm quan trọng của tầng giáo viên. Cụ thể, chỉ số tầng của mô hình giáo viên được ánh xạ sang mô hình học sinh thông qua tỷ lệ độ sâu $\lfloor \frac{L_S}{L_T} \rfloor$, từ đó thu được tập tầng tương ứng của mô hình học sinh I_S . Do mô hình giáo viên thường sâu hơn mô hình học sinh, phép ánh xạ này có thể dẫn đến trường hợp nhiều tầng giáo viên cùng được gán vào một tầng học sinh, tạo thành ánh xạ “nhiều-đến-một”.

Ví dụ, giả sử $L_T = 24$, $L_S = 12$, và các tầng được lựa chọn của mô hình giáo viên là $I_T = \{3, 4, 5, 6, 7, 8, 9, 10\}$, thì phép ánh xạ theo độ sâu tương đối sẽ gộp các cặp tầng giáo viên vào cùng một tầng học sinh (chẳng hạn $3, 4 \rightarrow 2$; $5, 6 \rightarrow 3$; v.v.). Trong trường hợp này, việc coi các tầng giáo viên đóng góp như nhau là không hợp lý, do mức độ quan trọng của chúng có thể khác biệt đáng kể.

Để chuyển điểm Block Influence thành trọng số đóng góp giữa các tầng giáo viên, đề án sử dụng hàm softmax với tham số nhiệt độ τ :

$$w_k^T = \frac{\exp(BI_k/\tau)}{\sum_{j \in I_k} \exp(BI_j/\tau)}$$

Trong đó τ điều khiển mức độ tập trung của phân phối trọng số, cho phép cân bằng giữa việc nhấn mạnh các tầng có BI cao và duy trì tính ổn định trong quá trình huấn luyện. Cách chuẩn hóa này đảm bảo rằng các trọng số phản ánh đúng sự phân bố đóng góp giữa các tầng giáo viên, đồng thời cho phép mô hình học sinh học một cách mềm dẻo từ nhiều tầng giáo viên khác nhau thay vì phụ thuộc vào một ánh xạ

cứng nhắc.

Các trọng số w_k^T sau đó được sử dụng trực tiếp trong hàm mất mát chất lọc, giúp quá trình huấn luyện ưu tiên các tầng chứa nhiều thông tin ngữ nghĩa quan trọng và giảm ảnh hưởng của các tầng có mức đóng góp thấp. Nhờ đó, cơ chế căn chỉnh giữa các tầng không chỉ giải quyết sự khác biệt về độ sâu kiến trúc mà còn nâng cao hiệu quả và tính ổn định của quá trình chất lọc tri thức.

3.5 Căn chỉnh giữa các bộ mã hóa (Cross-Tokenizer Alignment)

Trong bối cảnh mô hình giáo viên và mô hình học sinh sử dụng các tokenizer khác nhau, việc căn chỉnh tri thức ở cấp độ token trở nên đặc biệt thách thức do không tồn tại sự tương ứng một-một rõ ràng giữa các token của hai mô hình. Một token của mô hình học sinh có thể tương ứng với nhiều token của mô hình giáo viên và ngược lại, khiến các phương pháp chất lọc truyền thống dựa trên căn chỉnh cứng theo vị trí hoặc theo token không còn phù hợp.

Để giải quyết vấn đề này, đề án đề xuất một cơ chế căn chỉnh mềm giữa các bộ mã hóa (*cross-tokenizer alignment*), kết hợp đồng thời hai nguồn thông tin bổ sung cho nhau: (i) thông tin hình học toàn cục trong không gian nhúng và (ii) thông tin ngữ cảnh cục bộ từ các trạng thái ẩn của mô hình. Cách tiếp cận này cho phép mô hình học sinh tiếp nhận tri thức từ mô hình giáo viên một cách linh hoạt, phản ánh đúng cả mối quan hệ ngữ nghĩa tổng quát giữa các token lẫn vai trò ngữ cảnh cụ thể của chúng trong từng câu.

Căn chỉnh ngữ cảnh theo span và tầng. Mặc dù ánh xạ hình học toàn cục cung cấp một prior quan trọng, nó không phản ánh được vai trò ngữ cảnh của token trong từng câu cụ thể. Do đó, phương pháp tiếp tục khai thác thông tin từ các trạng thái ẩn của mô hình giáo viên.

Đối với mỗi token học sinh x_i^S , tập các token giáo viên có vùng bao (*span*) chồng chéo trong chuỗi gốc được xác định:

$$\mathbf{O}_i = \{x_j^T \mid \text{span}_S[x_i^S] \cap \text{span}_T[x_j^T] \neq \emptyset\}.$$

Với mỗi tầng $k \in I_T$ của mô hình giáo viên, trạng thái ẩn của token x_j^T sau khi được chiếu sang không gian của mô hình học sinh được ký hiệu là:

$$H_{T \rightarrow S}^k[x_j^T] = W_{T \rightarrow S}^k \left(H_T^k[x_j^T] \right), \quad (3.2)$$

trong đó $W_{T \rightarrow S}^k$ là ma trận chiếu có thể huấn luyện.

Căn chỉnh hình học toàn cục. Trước hết, một ánh xạ toàn cục giữa không gian từ vựng của hai mô hình dựa trên hình học của các vector nhúng được xây dựng. Cách tiếp cận này được xem như một dạng tri thức nền tảng, phản ánh mối quan hệ ngữ nghĩa tổng quát giữa các token, độc lập với ngữ cảnh cụ thể của câu. Để thực hiện điều này, đề án sử dụng khuôn khổ *Optimal Transport* (OT) [13], vốn cho phép căn chỉnh hai phân phối rời rạc trong các không gian metric khác nhau thông qua một ánh xạ mềm.

Cụ thể, một ma trận chi phí $C^{\text{emb}} \in \mathbb{R}^{|V_S| \times |V_T|}$ được xây dựng, trong đó mỗi phần tử biểu diễn độ khác biệt hình học giữa token học sinh và token giáo viên:

$$C_{i,j}^{\text{emb}} = 1 - \cos(E_S[x_i^S], E_T[x_j^T]), \quad (3.3)$$

với E_S và E_T lần lượt là các vector nhúng của mô hình học sinh và mô hình giáo viên (sau khi chiếu về cùng không gian).

Dựa trên ma trận chi phí này, bài toán optimal transport được định nghĩa như sau:

$$\mathbf{P}^* = \arg \min_{\mathbf{P} \in \Pi(\mathbf{p}, \mathbf{q})} \langle \mathbf{P}, \mathbf{C}^{\text{emb}} \rangle, \quad (3.4)$$

trong đó $\langle \mathbf{P}, \mathbf{C} \rangle = \sum_{i,j} P_{ij} C_{ij}$ là tích vô hướng Frobenius. Tập khả thi $\Pi(\mathbf{p}, \mathbf{q})$ bao gồm tất cả các kế hoạch vận chuyển thỏa mãn các ràng buộc bảo toàn phân phối biên:

$$\sum_j P_{ij} = p_i, \quad \forall i, \quad (3.5)$$

$$\sum_i P_{ij} = q_j, \quad \forall j, \quad (3.6)$$

$$P_{ij} \geq 0, \quad (3.7)$$

với $\mathbf{p}$ và $\mathbf{q}$ lần lượt là các phân phối xác suất trên từ vựng của mô hình học sinh và mô hình giáo viên (trong thực nghiệm, thường được chọn là phân phối đều).

Nghiệm tối ưu $\mathbf{P}^*$ không phải là một ánh xạ cứng gán toàn bộ khối lượng vào cặp token gần nhau nhất, mà là một ánh xạ mềm thỏa mãn đồng thời các ràng buộc biên. Do đó, mỗi token học sinh có thể phân phối khối lượng của mình lên nhiều token giáo viên có ngữ nghĩa tương đồng, phản ánh đúng bản chất nhiều–nhiều của bài toán căn chỉnh giữa các tokenizer khác nhau. Trong đề án này, ma trận ánh xạ toàn cục này được ký hiệu là M_{global} .

Do phải thỏa mãn các ràng buộc bảo toàn phân phối biên, các giá trị tuyệt đối của M_{global} thường rất nhỏ, đặc biệt khi kích thước từ vựng của hai mô hình lớn. Để

khắc phục vấn đề này, thay vì sử dụng trực tiếp các giá trị tuyệt đối của M_{global} , các giá trị này được chuẩn hóa theo từng token học sinh:

$$\hat{M}_{\text{global}}[x_i^S, x_j^T] = \frac{M_{\text{global}}[x_i^S, x_j^T]}{\sum_{x_{j'}^T \in \mathbf{O}_i} M_{\text{global}}[x_i^S, x_{j'}^T]}, \quad (3.8)$$

Phép chuẩn hóa này giúp chuyển M_{global} thành một phân phối tương đối trên tập token giáo viên có span chéo, đồng thời loại bỏ ảnh hưởng của độ lớn tuyệt đối và giữ lại thông tin hình học có ý nghĩa so sánh.

Kết hợp hình học và ngữ cảnh. Đối với mỗi cặp token (x_i^S, x_j^T) với $x_j^T \in \mathbf{O}_i$, một điểm căn chỉnh lai tại tầng k được tính như sau:

$$A_{i,j,k} = (1 - \eta) \cos(H_S^k[x_i^S], H_{T \rightarrow S}^k[x_j^T]) + \eta \hat{M}_{\text{global}}[x_i^S, x_j^T], \quad (3.9)$$

trong đó $\eta \in [0, 1]$ là siêu tham số điều chỉnh mức độ đóng góp tương đối giữa thông tin ngữ cảnh cục bộ và ánh xạ hình học toàn cục. Theo cách này, M_{global} đóng vai trò như một *prior* mềm, định hướng quá trình căn chỉnh theo ngữ cảnh thay vì chỉ phối trực tiếp biểu diễn ẩn.

Các điểm căn chỉnh $A_{i,j,k}$ sau đó được chuyển thành các trọng số đóng góp thông qua hàm softmax có hệ số nhiệt độ, áp dụng trên tập các token giáo viên $\mathbf{O}_i$ tương ứng với token học sinh x_i^S :

$$a_{i,j,k} = \frac{\exp(A_{i,j,k}/\tau)}{\sum_{x_{j'}^T \in \mathbf{O}_i} \exp(A_{i,j',k}/\tau)}, \quad (3.10)$$

trong đó $\tau > 0$ là tham số nhiệt độ điều chỉnh mức độ sắc nét của phân bố trọng số. Khi τ nhỏ, cơ chế căn chỉnh trở nên chọn lọc hơn, tập trung vào các token giáo viên có mức độ phù hợp cao; ngược lại, khi τ lớn, phân bố trọng số trở nên mượt hơn và cho phép tổng hợp thông tin từ nhiều token giáo viên.

Khác với ánh xạ hình học toàn cục, các điểm căn chỉnh $A_{i,j,k}$ được sử dụng như các score thể hiện mức độ phù hợp ngữ cảnh giữa các token. Do đó, hàm softmax được áp dụng nhằm thực hiện một cơ chế chọn lọc mềm, tương tự attention, giúp mô hình học sinh tập trung vào những token giáo viên mang thông tin ngữ nghĩa liên quan nhất trong ngữ cảnh cụ thể.

Dựa trên các trọng số này, biểu diễn tổng hợp của mô hình giáo viên tương ứng với token học sinh x_i^S tại tầng k được tính bằng tổng có trọng số của các trạng thái

ẩn đã được chiếu:

$$\tilde{H}_{i,k}^T = \sum_{x_j^T \in \mathbf{O}_i} a_{i,j,k} \cdot H_{T \rightarrow S}^k[x_j^T]. \quad (3.11)$$

Biểu diễn $\tilde{H}_{i,k}^T$ này được sử dụng trực tiếp trong hàm mất mát chất lọc nhằm truyền tri thức từ mô hình giáo viên sang mô hình học sinh một cách hiệu quả, đồng thời giải quyết tự nhiên sự lệch pha giữa các bộ tokenizer khác nhau.

3.6 Hàm mục tiêu tổng thể (Overall Objective)

Trong mục này, đề án xây dựng hàm mục tiêu huấn luyện cho phương pháp đề xuất nhằm kết hợp đồng thời quá trình học có giám sát truyền thống với các cơ chế chất lọc tri thức ở cả mức biểu diễn ẩn và mức phân phối đầu ra. Mục tiêu của hàm mất mát là giúp mô hình học sinh không chỉ bắt chước hành vi đầu ra của mô hình giáo viên, mà còn tiếp thu được các cấu trúc biểu diễn trung gian mang tính ngữ nghĩa sâu bên trong mô hình giáo viên.

Cụ thể, hàm mất mát chất lọc tri thức trong không gian ẩn được sử dụng, ký hiệu là $\mathcal{L}_{\text{Distill}}$, nhằm đo lường mức độ tương đồng giữa các biểu diễn đã được căn chỉnh của mô hình giáo viên và mô hình học sinh. Với mỗi token x_i^S của mô hình học sinh, và mỗi cặp tầng được căn chỉnh $(k, g(k))$ giữa mô hình giáo viên và mô hình học sinh, độ tương đồng được đo bằng *cosine similarity* giữa biểu diễn ẩn của mô hình học sinh $H_{i,g(k)}^S$ và biểu diễn đã được tổng hợp của mô hình giáo viên $\tilde{H}_{i,k}^T$. Hàm mất mát chất lọc được định nghĩa như sau:

$$\mathcal{L}_{\text{Distill}} = \frac{1}{S} \sum_{i=1}^S \sum_{k \in I_T} w_k^T \cdot \left(1 - \cos \left(H_{i,g(k)}^S, \tilde{H}_{i,k}^T \right) \right) \quad (3.12)$$

trong đó S là số lượng token của chuỗi đầu vào ở mô hình học sinh, I_T là tập các tầng giáo viên được lựa chọn theo chỉ số Block Influence, và w_k^T là trọng số phản ánh mức độ quan trọng của tầng giáo viên thứ k , được tính theo Công thức ???. Việc đưa trọng số w_k^T vào hàm mất mát cho phép mô hình học sinh tập trung học từ những tầng chứa nhiều thông tin hữu ích nhất của mô hình giáo viên, đồng thời giảm ảnh hưởng của các tầng có mức đóng góp thấp hoặc mang nhiều nhiễu.

Hàm mất mát $\mathcal{L}_{\text{Distill}}$ đại diện cho quá trình căn chỉnh trong không gian biểu diễn ẩn giữa mô hình giáo viên và mô hình học sinh. Bên cạnh đó, để đảm bảo mô hình học sinh vẫn duy trì khả năng tái tạo chính xác phân phối đầu ra của mô hình giáo viên, phương pháp kết hợp thêm hàm mất mát $\mathcal{L}_{\text{DSKD}}$, đại diện cho quá trình căn chỉnh ở mức logits đầu ra dựa trên phương pháp Dual-Space Knowledge Distillation đã được trình bày ở Mục 2.6.2.

Tổng hợp lại, hàm mục tiêu huấn luyện cuối cùng của mô hình học sinh được định nghĩa như sau:

$$\mathcal{L} = \alpha \mathcal{L}_{\text{CE}} + \beta \mathcal{L}_{\text{Distill}} + \gamma \mathcal{L}_{\text{DSKD}} \quad (3.13)$$

trong đó $\mathcal{L}_{\text{CE}}$ là hàm mất mát *cross-entropy* truyền thống dùng cho huấn luyện có giám sát, còn α , β và γ là các siêu tham số điều chỉnh mức độ đóng góp tương đối của từng thành phần mất mát. Việc kết hợp đồng thời ba thành phần này cho phép mô hình học sinh vừa học được nhãn mục tiêu, vừa kế thừa được tri thức ở cả mức biểu diễn trung gian và mức phân phối đầu ra của mô hình giáo viên.

Trong ba thành phần của hàm mục tiêu, mỗi thành phần đảm nhiệm một vai trò riêng biệt. Thành phần $\mathcal{L}_{\text{CE}}$ giúp mô hình học sinh duy trì khả năng học có giám sát và đảm bảo sự ổn định trong quá trình huấn luyện. Thành phần $\mathcal{L}_{\text{Distill}}$ đóng vai trò truyền tải tri thức cấu trúc ở mức biểu diễn ẩn, giúp mô hình học sinh học được các đặc trưng ngữ nghĩa sâu mà không thể quan sát trực tiếp từ nhãn đầu ra.

Trong khi đó, $\mathcal{L}_{\text{DSKD}}$ giúp mô hình học sinh căn chỉnh phân phối đầu ra với mô hình giáo viên. Sự kết hợp của ba thành phần này cho phép mô hình học sinh đồng thời học đúng nhiệm vụ, kế thừa tri thức trung gian, và duy trì sự nhất quán với hành vi đầu ra của mô hình giáo viên.

Nhờ đó, hàm mục tiêu tổng hợp không chỉ giúp mô hình học sinh bắt chước kết quả cuối cùng của mô hình giáo viên, mà còn khai thác hiệu quả cấu trúc biểu diễn nội tại của mô hình giáo viên, từ đó nâng cao hiệu quả chất lọc tri thức trong bối cảnh có sự khác biệt về tokenizer và độ sâu kiến trúc giữa hai mô hình.

3.7 Tổng kết

Tóm lại, phương pháp đề xuất trong đồ án này giải quyết bài toán chất lọc tri thức giữa các mô hình ngôn ngữ lớn có sự khác biệt về tokenizer và độ sâu kiến trúc thông qua ba thành phần chính: phép chiếu từ vựng, căn chỉnh cross-tokenizer, và căn chỉnh tầng có nhận thức tầm quan trọng.

Cụ thể, phép chiếu từ vựng được khởi tạo dựa trên các token trùng nhau giữa hai mô hình, tạo nên cầu nối ổn định giữa các không gian biểu diễn khác nhau. Cơ chế căn chỉnh cross-tokenizer kết hợp ánh xạ hình học toàn cục thông qua Optimal Transport với thông tin ngữ cảnh từ các trạng thái ẩn, cho phép căn chỉnh chính xác giữa các token có span trùng lặp. Đối với căn chỉnh tầng, phương pháp sử dụng chỉ số Block Influence để xác định các tầng quan trọng của mô hình giáo viên, đồng thời áp dụng cơ chế attention-based alignment để mô hình học sinh tự học trọng số đóng góp giữa các tầng, tránh các ánh xạ cứng nhắc.

Hàm mục tiêu tổng thể kết hợp hàm mất mát cross-entropy truyền thống với hàm

mất mát chất lọc dựa trên cosine similarity giữa các biểu diễn đã được căn chỉnh, giúp mô hình học sinh không chỉ học từ đầu ra cuối cùng mà còn nắm bắt được cấu trúc biểu diễn trung gian quan trọng từ mô hình giáo viên.

Trong phạm vi nghiên cứu này, các siêu tham số như số lượng tầng được chọn, hệ số kết hợp giữa các thành phần trong hàm mất mát, và tham số điều chỉnh giữa ánh xạ hình học và ngữ cảnh được lựa chọn dựa trên kinh nghiệm và quan sát thực nghiệm. Với cách tiếp cận này, phương pháp đã cho thấy khả năng truyền tri thức hiệu quả giữa các mô hình có sự khác biệt về tokenizer và độ sâu. Trong tương lai, có thể mở rộng bằng cách tự động hóa việc lựa chọn các siêu tham số này thông qua các kỹ thuật tối ưu hóa siêu tham số hoặc tối đa trọng số tự động, từ đó nâng cao hơn nữa hiệu quả của phương pháp.

Nhìn chung, phương pháp đề xuất với sự kết hợp của phép chiếu từ vệt thông minh, căn chỉnh đa cấp độ và cơ chế học trọng số động đã mở ra một hướng tiếp cận hiệu quả cho bài toán chất lọc tri thức trong các mô hình ngôn ngữ lớn, đặc biệt trong bối cảnh có sự không tương thích về tokenizer và kiến trúc.

CHƯƠNG 4. ĐÁNH GIÁ THỰC NGHIỆM

4.1 Dữ liệu huấn luyện và đánh giá

Trong đồ án này, các thí nghiệm chất lọc tri thức được tiến hành trên nhiều bộ dữ liệu thuộc dạng *instruction-following*, nhằm đánh giá toàn diện khả năng học tập và tổng quát hóa của mô hình học sinh. Việc lựa chọn các bộ dữ liệu đa dạng không chỉ giúp đánh giá hiệu quả huấn luyện trên miền dữ liệu quen thuộc, mà còn cho phép kiểm tra khả năng suy luận và thích ứng của mô hình trong các kịch bản ngoài phân phối (out-of-distribution).

4.1.1 Dữ liệu huấn luyện

Quá trình huấn luyện chất lọc tri thức chủ yếu được thực hiện trên bộ dữ liệu Databricks-Dolly-15K [14]. Đây là tập dữ liệu gồm khoảng 15.000 cặp hướng dẫn – phản hồi (instruction-response), được xây dựng nhằm phục vụ huấn luyện và đánh giá các mô hình ngôn ngữ lớn trong các tác vụ theo sát chỉ dẫn. Dolly-15K bao phủ nhiều dạng nhiệm vụ khác nhau như trả lời câu hỏi, tóm tắt văn bản, hội thoại, giải thích, phân tích và suy luận. Các mẫu dữ liệu đều được kiểm duyệt kỹ lưỡng, đảm bảo chất lượng và sự đa dạng về nội dung, qua đó tạo điều kiện thuận lợi cho quá trình chuyển giao tri thức.

4.1.2 Dữ liệu đánh giá

Để đánh giá khả năng tổng quát hóa của mô hình học sinh sau quá trình chất lọc tri thức, đồ án sử dụng thêm một số bộ dữ liệu kiểm thử ngoài phân phối, bao gồm:

- **Super-Natural-Instructions (S-NI)** [15]: Bộ dữ liệu quy mô lớn, bao gồm nhiều nhiệm vụ hướng dẫn phức tạp thuộc nhiều lĩnh vực khác nhau, thường được sử dụng để đánh giá khả năng suy luận tổng quát của các mô hình ngôn ngữ.
- **Vicuna Evaluation (VICUNAEVAL)** [16]: Tập benchmark được thiết kế nhằm đánh giá chất lượng phản hồi hội thoại tự nhiên của mô hình.
- **DialogSum** [17]: Bộ dữ liệu chuyên cho tác vụ tóm tắt hội thoại, giúp kiểm tra khả năng hiểu ngữ cảnh và tổng hợp thông tin trong các cuộc đối thoại nhiều lượt.
- **Self-Instruct** [18]: Bộ dữ liệu được tạo ra bằng cách sử dụng khả năng sinh dữ liệu hướng dẫn của mô hình ngôn ngữ lớn để tạo ra các cặp instruction-response có chất lượng cao. Self-Instruct không chỉ bao gồm các ví dụ được thu thập thủ công mà còn được sinh tự động theo các quy tắc hướng dẫn nhằm mở rộng sự đa dạng của nhiệm vụ. Tập dữ liệu này được sử dụng rộng rãi để

huấn luyện và đánh giá khả năng theo sát yêu cầu của mô hình đối với nhiều loại nhiệm vụ khác nhau, từ trả lời câu hỏi đến sinh văn bản có cấu trúc, giúp đánh giá khả năng tổng quát hóa và thích nghi của các mô hình học sinh trong bối cảnh instruction-following.

Việc kết hợp tập huấn luyện chính cùng các bộ dữ liệu kiểm thử ngoài phân phối cho phép đánh giá toàn diện hiệu quả chất lọc tri thức cũng như năng lực tổng quát hóa của mô hình học sinh trên nhiều miền nhiệm vụ khác nhau.

4.2 Mô hình giáo viên và mô hình học sinh

Việc lựa chọn cặp mô hình giáo viên và học sinh đóng vai trò quan trọng trong quá trình thực nghiệm, đặc biệt khi mục tiêu của đề án là kiểm chứng khả năng chất lọc tri thức giữa các mô hình có sự khác biệt đáng kể về quy mô, kiến trúc và tokenizer. Do đó, các mô hình được lựa chọn đại diện cho nhiều họ kiến trúc và mức độ phức tạp khác nhau.

4.2.1 Qwen1.5-1.8B (giáo viên) → GPT2-120M (học sinh)

Qwen1.5-1.8B [4] là mô hình ngôn ngữ lớn với khoảng 1,8 tỷ tham số, đóng vai trò là phiên bản tiền đề cho Qwen2. Mô hình được huấn luyện trên tập dữ liệu đa dạng, tối ưu cho các tác vụ hội thoại và hỗ trợ đa ngôn ngữ, với khả năng xử lý ngữ cảnh dài lên tới 32.000 token. Nhờ quy mô lớn và các kỹ thuật huấn luyện tiên tiến, Qwen1.5-1.8B đạt hiệu năng cao trên nhiều bộ đánh giá chuẩn.

GPT2-120M [5] là phiên bản thu gọn của GPT-2 với 120 triệu tham số, phù hợp cho các kịch bản triển khai hạn chế tài nguyên. Việc lựa chọn mô hình này làm học sinh giúp đánh giá khả năng truyền tri thức từ mô hình lớn sang mô hình nhỏ, đồng thời phản ánh các yêu cầu thực tiễn trong triển khai.

4.2.2 Mistral-7B (giáo viên) → TinyLLaMA-1.1B (học sinh)

Mistral-7B [6] là mô hình ngôn ngữ với 7 tỷ tham số, được tối ưu hóa cả về hiệu suất và chất lượng sinh văn bản. Mô hình cho thấy hiệu năng vượt trội so với LLaMA2-13B trên nhiều benchmark và sử dụng tokenizer riêng biệt, tạo ra sự khác biệt rõ rệt so với các mô hình nhỏ hơn.

TinyLLaMA-1.1B [7] là phiên bản rút gọn của họ LLaMA, gồm khoảng 1,1 tỷ tham số và được huấn luyện trên tập dữ liệu quy mô lớn. Mô hình này hướng tới sự cân bằng giữa hiệu suất và chi phí tính toán, phù hợp cho các ứng dụng thực tế yêu cầu mô hình gọn nhẹ nhưng vẫn đảm bảo chất lượng.

4.2.3 Qwen2.5-7B-Instruct (giáo viên) → GPT-2 1.5B (học sinh)

Qwen2.5-7B-Instruct là mô hình ngôn ngữ khoảng 7 tỷ tham số, được tinh chỉnh chuyên biệt cho các tác vụ theo sát chỉ dẫn. Mô hình hỗ trợ đa ngôn ngữ và

nhiều miền nhiệm vụ khác nhau như toán học, lập trình và xử lý dữ liệu có cấu trúc.

GPT-2 1.5B là phiên bản lớn nhất của dòng GPT-2, với ưu điểm về chi phí tính toán và tốc độ suy luận so với các LLM hiện đại hơn. Mô hình này thường được sử dụng làm học sinh trong các bài toán chất lọc tri thức nhằm tận dụng năng lực của mô hình giáo viên lớn.

4.2.4 Lý do lựa chọn

Các cặp mô hình trên được lựa chọn nhằm:

- Đánh giá hiệu quả của phương pháp chất lọc tri thức trong các kịch bản khác biệt lớn về quy mô, kiến trúc và tokenizer.
- Kiểm chứng khả năng truyền tri thức giữa các họ mô hình ngôn ngữ phổ biến hiện nay.
- Đảm bảo tính thực tiễn, khi mô hình học sinh có kích thước phù hợp triển khai, trong khi mô hình giáo viên đủ mạnh để tạo ra chênh lệch rõ rệt về năng lực.

4.3 Chỉ số đánh giá ROUGE-L

Trong các bài toán sinh ngôn ngữ tự nhiên, việc đánh giá chất lượng đầu ra của mô hình là một thách thức do tính đa dạng trong cách diễn đạt. ROUGE-L [19] là một trong những chỉ số đánh giá phổ biến, được sử dụng rộng rãi để đo mức độ tương đồng giữa văn bản sinh ra và văn bản tham chiếu.

ROUGE-L dựa trên độ dài của chuỗi con chung dài nhất (Longest Common Subsequence – LCS) giữa hai văn bản, cho phép đánh giá linh hoạt các trường hợp diễn đạt khác nhau nhưng vẫn giữ nguyên thứ tự ý nghĩa.

Giả sử câu sinh ra $X = [x_1, x_2, \dots, x_m]$ và câu tham chiếu $Y = [y_1, y_2, \dots, y_n]$, các độ đo được xác định như sau:

$$R_{LCS} = \frac{LCS(X, Y)}{|Y|}, \quad (4.1)$$

$$P_{LCS} = \frac{LCS(X, Y)}{|X|}, \quad (4.2)$$

$$F_{LCS} = \frac{(1 + \beta^2)R_{LCS}P_{LCS}}{R_{LCS} + \beta^2 P_{LCS}}, \quad (4.3)$$

trong đó β thường được đặt bằng 1 để cân bằng giữa recall và precision. Trong thực nghiệm, ROUGE-L thường được báo cáo dưới dạng F1-score.

Nhờ đặc tính dựa trên LCS, ROUGE-L đặc biệt phù hợp với các tác vụ như tóm

tất hoặc sinh câu trả lời, nơi thứ tự các ý chính đóng vai trò quan trọng. Trong nghiên cứu này, ROUGE-L được sử dụng làm chỉ số chính để đánh giá chất lượng đầu ra của mô hình học sinh, phản ánh mức độ mô hình học được nội dung và cách diễn đạt từ mô hình giáo viên.

4.3.1 Lựa chọn các phương pháp so sánh

Để đánh giá toàn diện hiệu quả của phương pháp đề xuất, nhiều phương pháp baselines khác nhau được lựa chọn để so sánh, bao gồm cả các kỹ thuật huấn luyện có giám sát truyền thống lẫn các phương pháp chất lọc tri thức tiên tiến, đặc biệt là các phương pháp được thiết kế nhằm giải quyết vấn đề khác biệt về tokenizer và vốn từ vựng giữa các mô hình.

Cụ thể, các baselines được sử dụng trong thực nghiệm bao gồm:

- **Supervised Fine-tuning (SFT):** Huấn luyện mô hình học sinh trực tiếp trên dữ liệu hướng dẫn (instruction-following) mà không sử dụng tri thức từ mô hình giáo viên. Đây là chuẩn tham chiếu cơ bản giúp đánh giá lợi ích thực sự của các phương pháp chất lọc tri thức.
- **ULD:** Phương pháp chất lọc tri thức sử dụng khoảng cách Wasserstein trong hàm mất mát thay vì KL divergence (chỉ hỗ trợ cùng tokenizer) để vượt qua rào cản khác biệt tokenizer. Qua đó, phương pháp đã đạt được nhiều kết quả đáng chú ý trên nhiều tác vụ khác nhau như trả lời câu hỏi và tóm tắt.
- **DSKD:** Dual-Space Knowledge Distillation, một kỹ thuật chất lọc tri thức với mong muốn chuyển phân phối đầu ra của hai model giáo viên và học sinh có cùng tokenizer về cùng một không gian gọi là không gian hợp nhất. Ngoài ra, với cặp mô hình khác tokenizer, phương pháp định nghĩa cơ chế Cross-Model Attention học sự liên kết giữa các token của teacher và student bằng attention, giúp căn chỉnh biểu diễn ẩn giữa hai mô hình có tokenizer khác nhau.
- **MultiLevelOT:** Là một phương pháp chất lọc tri thức mạnh mẽ, sử dụng tối ưu nhiều mức, kết hợp các hàm chi phí khác nhau để căn chỉnh phân phối giữa teacher và student, hai mô hình có thể có sự khác nhau về kiến trúc và tokenizer. Không chỉ cải thiện hàm mất mát theo token-level của ULD, phương pháp đề xuất thêm hàm mất mát ở sequence-level học sự liên kết tổng thể của toàn chuỗi đầu ra, nhưng vẫn chỉ dừng lại ở duy nhất một không gian đầu ra của mô hình.

Việc lựa chọn các baseline đa dạng này giúp thiết lập một khung đánh giá toàn diện, từ đó kiểm chứng khả năng xử lý sự khác biệt về tokenizer và vốn từ vựng của phương pháp đề xuất.

4.3.2 Các tham số huấn luyện

Các tham số huấn luyện cho hai cặp mô hình được trình bày trong Bảng 4.1. Cụ thể, hai cặp được sử dụng là Qwen (giáo viên) với GPT2 (học sinh), và Mistral (giáo viên) với TinyLLaMA (học sinh).

Bảng 4.1: Cấu hình huấn luyện chi tiết cho các cặp mô hình.

Tham số	GPT2-120M	Qwen1.5	GPT2-1.5B	Qwen2.5	TinyLLaMA	Mistral
Số epoch	20	15	15	15	15	15
Learning rate	5×10^{-4}	2×10^{-5}	5×10^{-4}	1×10^{-3}	1×10^{-3}	1×10^{-3}
Projector LR	1×10^{-3}	1×10^{-3}	1×10^{-3}	1×10^{-3}	1×10^{-3}	1×10^{-3}
Batch size	8	8	8	8	8	8
Scheduler	Cosine	Cosine	Cosine	Cosine	Cosine	Cosine
Fine-tuning	Full	Full	LoRA	LoRA	LoRA	LoRA
LoRA Rank	N/A	N/A	256	256	256	256
LoRA Alpha	N/A	N/A	8	8	8	8
LoRA Dropout	N/A	N/A	0.1	0.1	0.1	0.1

Các tham số được lựa chọn dựa trên cấu hình tham khảo từ phương pháp DSKD [2]. Do hàm mất mát đề xuất được phát triển và kế thừa gián tiếp từ DSKD, các tham số này được sử dụng làm cấu hình thử nghiệm chính. Trong đó, các mô hình sử dụng LoRA[20] đều có cùng thông số về rank, alpha và dropout. Các mô hình không sử dụng LoRA[20] thì huấn luyện toàn bộ tham số (full fine-tuning).

4.4 Kết quả và Đánh giá

Bảng 4.2 trình bày kết quả so sánh các phương pháp chất lọc trên ba cặp mô hình: Qwen1.5-1.8B → GPT2-120M, Mistral-7B → TinyLLaMA-1.1B và Qwen2.5-7B-Instruct → GPT2-1.5B, đánh giá trên năm bộ dữ liệu: Dolly, S-NI, SelfInst, Dialogsum, VicunaEval và điểm trung bình (Avg.). Kết quả được báo cáo dưới dạng điểm số trung bình năm lần chạy.

Hiệu quả tổng thể của phương pháp đề xuất

Từ Bảng 4.2, có thể thấy phương pháp W-CTKD đạt hiệu quả tốt và ổn định trên cả ba cặp mô hình, vượt trội so với các baseline trong hầu hết các thiết lập. Đặc biệt, W-CTKD ổn định đạt điểm trung bình cao nhất trên cả ba cặp giáo viên–học sinh, cho thấy khả năng tổng quát hóa tốt ngay cả khi tồn tại sự khác biệt lớn về kiến trúc và tokenizer.

Trên cặp Qwen1.5-1.8B → GPT2-120M, W-CTKD đạt điểm trung bình 14.85, cải thiện so với DSKD (14.76) và vượt xa các phương pháp dựa thuần trên căn chỉnh phân phối như ULD và MultiLevelOT. Xu hướng tương tự được quan sát trên cặp Mistral-7B → TinyLLaMA-1.1B, nơi W-CTKD đạt 20.96, cao hơn so với DSKD (20.83) và ULD (20.76).

Bảng 4.2: So sánh hiệu quả các phương pháp chất lọc trên ba cặp mô hình (ROUGE-L, trung bình 5 lần chạy).

Phương pháp	Dolly	S-NI	SelfInst	DialogSum	VicunaEval	Avg.
Qwen1.5-1.8B → GPT2-120M						
Teacher	28.23	34.36	19.58	14.18	19.59	23.19
SFT	22.88	13.95	9.34	9.49	14.58	14.05
ULD	22.97	14.26	9.27	8.75	14.65	13.98
DSKD	24.21	15.21	9.87	9.43	15.08	14.76
MultiLevelOT	22.78	12.19	8.10	8.97	13.61	13.13
W-CTKD	24.40	15.74	9.58	9.42	15.10	14.85
Mistral-7B → TinyLLaMA-1.1B						
Teacher	32.15	36.88	25.44	14.67	20.43	25.91
SFT	23.20	28.43	15.70	10.77	15.70	18.76
ULD	25.48	31.54	17.72	11.75	17.31	20.76
DSKD	25.78	30.93	17.19	12.53	17.74	20.83
MultiLevelOT	24.56	27.91	15.61	12.04	16.84	19.39
W-CTKD	26.05	30.85	17.48	12.45	17.95	20.96
Qwen2.5-7B-Instruct → GPT2-1.5B						
Teacher	28.49	39.87	24.67	16.86	20.48	26.07
SFT	21.83	21.66	13.62	10.91	15.95	16.79
ULD	24.52	26.18	15.11	11.72	15.94	18.69
DSKD	25.19	25.73	15.94	12.27	16.88	19.20
MultiLevelOT	24.40	23.94	14.53	10.84	15.97	17.94
W-CTKD	26.46	26.28	16.27	12.15	16.24	19.48

Đáng chú ý, trong thiết lập Qwen2.5-7B-Instruct → GPT2-1.5B, W-CTKD đạt điểm trung bình 19.48, cho thấy khả năng khai thác hiệu quả tri thức từ mô hình giáo viên có quy mô lớn và được tinh chỉnh theo hướng instruction-following.

Phân tích theo từng bộ dữ liệu.

Xét trên từng bộ dữ liệu cụ thể, phương pháp W-CTKD cho thấy hiệu năng ổn định và có xu hướng vượt trội so với các phương pháp so sánh trong hầu hết các thiết lập. Trên bộ dữ liệu huấn luyện Dolly, W-CTKD consistently đạt điểm ROUGE-L cao nhất trên cả ba cặp mô hình, cho thấy khả năng khai thác hiệu quả tri thức từ mô hình giáo viên trong miền dữ liệu quen thuộc mà không làm suy giảm khả năng sinh phản hồi theo sát chỉ dẫn.

Đối với các bộ dữ liệu đánh giá ngoài phân phối như S-NI và Self-Instruct, W-CTKD tiếp tục duy trì lợi thế rõ rệt so với SFT và các phương pháp chất lọc truyền thống, đồng thời đạt kết quả tương đương hoặc tốt hơn DSKD trong phần lớn các trường hợp. Điều này cho thấy cơ chế căn chỉnh cross-tokenizer kết hợp với học trọng số theo token giúp mô hình học sinh tiếp thu tốt hơn các tri thức suy luận và

Bảng 4.3: Ảnh hưởng của số tầng giáo viên và chiến lược khởi tạo trong W-CTKD (Qwen2.5-7B-Instruct → GPT2-1.5B).

Cấu hình	Dolly	S-NI	SelfInst	Dialog	Vicuna	Avg.
W-CTKD (8 layers)	26.46	26.28	16.27	12.15	16.24	19.48
W-CTKD (4 layers)	25.59	25.84	15.84	12.31	16.63	19.24
W-CTKD (12 layers)	26.29	26.23	15.79	12.24	16.45	19.40
W-CTKD (16 layers)	26.00	26.17	15.78	12.56	16.52	19.41
W-CTKD (no-init)	26.25	25.87	15.46	12.43	16.43	19.29

khả năng tổng quát hóa từ mô hình giáo viên, ngay cả khi tồn tại sự khác biệt lớn về tokenizer và độ sâu kiến trúc.

Trên các tác vụ chuyên biệt như tóm tắt hội thoại (DialogSum) và đánh giá hội thoại tự nhiên (VicunaEval), W-CTKD đạt hiệu năng cạnh tranh và ổn định, thường chỉ chênh lệch nhẹ so với phương pháp tốt nhất trong từng thiết lập. Kết quả này cho thấy phương pháp đề xuất không chỉ phù hợp với các tác vụ instruction-following tổng quát mà còn có khả năng thích ứng tốt với các bài toán đòi hỏi hiểu ngữ cảnh dài và sinh phản hồi tự nhiên.

Ảnh hưởng của số tầng ẩn giáo viên

Kết quả trong Bảng 4.3 cho thấy việc lựa chọn số tầng giáo viên tham gia chất lọc có ảnh hưởng đáng kể đến hiệu năng cuối cùng. Cấu hình sử dụng 8 tầng đạt kết quả tốt nhất với điểm trung bình 19.48, cho thấy đây là mức cân bằng hợp lý giữa lượng thông tin ngữ nghĩa được truyền tải và mức độ nhiễu.

Khi số tầng quá ít (4 tầng), mô hình học sinh không khai thác đầy đủ thông tin từ giáo viên, trong khi việc sử dụng quá nhiều tầng (12 hoặc 16 tầng) không mang lại cải thiện đáng kể và thậm chí làm suy giảm nhẹ hiệu năng. Điều này gợi ý rằng không phải mọi tầng của mô hình giáo viên đều đóng vai trò quan trọng trong quá trình chất lọc.

Ảnh hưởng của khởi tạo ma trận chiếu

Để đánh giá vai trò của chiến lược khởi tạo ma trận chiếu từ vệt, thí nghiệm so sánh giữa phương pháp W-CTKD có và không sử dụng khởi tạo dựa trên các token trùng nhau được tiến hành. Kết quả cho thấy cấu hình không sử dụng khởi tạo đạt điểm trung bình 19.29, thấp hơn so với mô hình đầy đủ (19.48).

Sự chênh lệch này cho thấy khởi tạo ma trận chiếu dựa trên các token chồng chéo giúp quá trình huấn luyện ổn định hơn và hỗ trợ căn chỉnh không gian biểu diễn hiệu quả hơn, đặc biệt trong giai đoạn đầu của quá trình chất lọc. Điều này khẳng định vai trò quan trọng của phép chiếu từ vệt như một cầu nối hình học

giữa hai mô hình có tokenizer khác nhau.

Nhận xét tổng hợp

Tổng hợp các kết quả thực nghiệm, phương pháp W-CTKD cho thấy hiệu quả rõ rệt so với các phương pháp chất lọc truyền thống và các phương pháp căn chỉnh đa không gian trước đó. Việc kết hợp căn chỉnh cross-tokenizer, lựa chọn tầng dựa trên mức độ quan trọng và cơ chế học trọng số động theo token giúp mô hình học sinh tiếp thu tri thức ngữ nghĩa sâu hơn từ mô hình giáo viên.

Các kết quả này cho thấy việc khai thác và căn chỉnh các biểu diễn tầng ẩn đóng vai trò quan trọng trong bài toán chất lọc tri thức cho mô hình ngôn ngữ lớn, đặc biệt trong các kịch bản thực tế nơi mô hình giáo viên và học sinh khác nhau đáng kể về tokenizer và độ sâu kiến trúc.

So sánh các phương pháp

- Các phương pháp chất lọc (distillation) như ULD[21] và MultiLevelOT[1] chưa đạt được hiệu quả như mong đợi, khi kết quả thường thấp hơn DSKD trên hầu hết các bộ dữ liệu.
- DSKD[2] cho thấy khả năng cải thiện đáng kể so với các phương pháp truyền thống, tuy nhiên vẫn chưa đạt được mức tối ưu so với phương pháp W-CTKD được đề xuất.
- Phương pháp W-CTKD thể hiện tốt hơn về khả năng chất lọc tri thức, đặc biệt nổi bật trên các bộ dữ liệu phức tạp như S-NI[15] và VicunaEval[16], đồng thời duy trì hiệu quả ổn định trên nhiều cặp mô hình khác nhau.

Kết luận

Những kết quả thực nghiệm đã chỉ ra rằng phương pháp W-CTKD không chỉ nâng cao hiệu quả chất lọc mà còn đảm bảo tính ổn định và nhất quán trên nhiều bộ dữ liệu cũng như các cặp mô hình sở hữu kiến trúc, tokenizer khác biệt. Điều này khẳng định tính tổng quát cao và tiềm năng mở rộng ứng dụng của phương pháp trong thực tiễn, góp phần thúc đẩy quá trình phát triển các mô hình ngôn ngữ nhẹ nhưng vẫn giữ được chất lượng đầu ra.

4.5 Một số kết quả khác

Các kết quả ở phần này nhằm đánh giá mô hình không chỉ dựa trên các chỉ số ROUGE-L[19] mà còn dựa trên chất lượng câu trả lời, tính chính xác.

Bảng 4.4: Một số kết quả so sánh giữa các phương pháp khác nhau với mô hình TinyLLaMA-1.1B.

Trường hợp #1	
Instruction	Who was Kyle Van Zyl playing against when he scored 36 of his team's 61 points?
Context	Van Zyl joined the Eastern Province Kings Academy, where he played for the Eastern Province U19 side in the 2010 Under-19 Provincial Championship. He was a key player for the Eastern Province U21 side in the 2012 Under-21 Provincial Championship, scoring 71 points in eight appearances. Van Zyl was under the Top SARU Performers, scoring the most tries at 6 in the 2012 Provincial Under 21 in the Rugby Junior Provincials. This included a record and a remarkable personal haul in their opening match, when he scored 36 of his team's points in a 61–3 victory over Boland U21, consisting of four tries and eight conversions and was awarded Man of the Match.
SFT	Van Zyl played against Boland U21.
ULD	Van Zyl played against Boland U21 in the 2012 Under-21 Provincial Championship.
DSKD	Kyle Van Zyl played against Boland U21 in the 2012 Under-21 Provincial Championship.
W-CTKD	Kyle Van Zyl played against Boland in their opening match and scored 36 of their 61 points.

Bảng 4.5: Một số kết quả so sánh giữa các phương pháp khác nhau với mô hình GPT2-1.5B.

Trường hợp #2	
Instruction	From the passage provided, extract the second studio album that Taylor Swift released.
Context	Swift signed a record deal with Big Machine Records in 2005 and released her eponymous debut album the following year. With 157 weeks on the Billboard 200 by December 2009, the album was the longest-charting album of the 2000s decade. Swift's second studio album, Fearless (2008), topped the Billboard 200 for 11 weeks and was the only album from the 2000s decade to spend one year in the top 10. The album was certified Diamond by the RIAA. It also topped charts in Australia and Canada, and has sold 12 million copies worldwide. Her third studio album, the self-written Speak Now (2010), spent six weeks atop the Billboard 200 and topped charts in Australia, Canada, and New Zealand.
SFT	Taylor Swift released Fearless in 2008.
ULD	Fearless
DSKD	Taylor Swift's third studio album, Fearless (2008), is one of the most critically acclaimed and commercially successful albums of her career, earning her six Grammy Awards, three Grammy Award-nomination, and two Grammy Award-winning Album of the Year awards. Taylor Swift's Fearless was certified Gold by the RIAA in 2010, with sales of more than 6 million units worldwide to date. The album also topped the Billboard 200 for 10 weeks, selling more than 5 million copies worldwide.
W-CTKD	Taylor Swift released her second studio album Fearless in 2008.

CHƯƠNG 5. KẾT LUẬN

Đồ án đã cơ bản hoàn thành các mục tiêu đề ra, tập trung nghiên cứu và ứng dụng các không gian đặc trưng khác nhau nhằm tối ưu hàm mất mát trong quá trình chất lọc tri thức mô hình ngôn ngữ lớn. Các chương trước đã trình bày đầy đủ những đóng góp về mặt lý thuyết cũng như thực nghiệm của đề tài. Chương này tổng kết lại những kết quả đã đạt được, đồng thời đề xuất các hướng nghiên cứu, phát triển tiếp theo dựa trên nền tảng và kết quả thực nghiệm của đồ án.

5.1 Kết luận

Đồ án này đã nghiên cứu và đề xuất một phương pháp chất lọc tri thức cho mô hình ngôn ngữ lớn, tập trung khai thác các biểu diễn trung gian của mô hình giáo viên nhằm truyền tải tri thức ngữ nghĩa sâu hơn cho mô hình học sinh. Khác với các phương pháp chưng cất truyền thống chủ yếu dựa trên việc bắt chước phân phối đầu ra, phương pháp của đồ án tiếp cận bài toán theo hướng căn chỉnh đa cấp độ, bao gồm không gian từ vựng, không gian token và không gian tầng ẩn của mô hình.

Đồ án tập trung giải quyết hai thách thức thực tiễn thường gặp trong chất lọc tri thức cho mô hình ngôn ngữ lớn: sự không tương thích giữa tokenizer và sự khác biệt về độ sâu kiến trúc giữa mô hình giáo viên và mô hình học sinh. Đối với vấn đề tokenizer, đồ án đề xuất cơ chế phép chiếu từ vựng được khởi tạo dựa trên các token trùng nhau giữa hai mô hình, đóng vai trò như các điểm neo giúp căn chỉnh hai không gian nhúng khác nhau một cách ổn định. Trên cơ sở đó, cơ chế căn chỉnh cross-tokenizer được xây dựng bằng cách kết hợp ánh xạ hình học toàn cục thông qua Optimal Transport với thông tin ngữ cảnh từ các trạng thái ẩn, cho phép thiết lập mối tương ứng linh hoạt giữa các token có span trùng lặp.

Đối với sự khác biệt về độ sâu mô hình, đồ án đề xuất chiến lược căn chỉnh tầng có xét đến tầm quan trọng, trong đó các tầng của mô hình giáo viên được đánh giá mức độ đóng góp thông qua chỉ số Block Influence. Thay vì truyền tri thức từ toàn bộ các tầng hoặc sử dụng ánh xạ tầng cứng nhắc, phương pháp chỉ tập trung vào các tầng quan trọng nhất và cho phép mô hình học sinh học trọng số đóng góp của từng tầng một cách linh hoạt theo từng token. Cách tiếp cận này giúp giảm nhiễu từ các tầng ít thông tin, đồng thời khai thác hiệu quả các biểu diễn ngữ nghĩa giàu thông tin của mô hình giáo viên.

Hàm mục tiêu tổng thể được xây dựng bằng cách kết hợp hàm mất mát cross-entropy truyền thống với hàm mất mát chưng cất dựa trên độ tương đồng cosine giữa các biểu diễn tầng ẩn đã được căn chỉnh, cùng với thành phần DSKD ở mức

đầu ra. Nhờ đó, mô hình học sinh không chỉ học cách dự đoán đầu ra tương tự mô hình giáo viên mà còn tiếp thu được cấu trúc biểu diễn nội tại của mô hình giáo viên trong các không gian ẩn khác nhau.

Các kết quả đạt được cho thấy phương pháp đề xuất có khả năng truyền tri thức hiệu quả trong bối cảnh mô hình giáo viên và học sinh khác nhau đáng kể về tokenizer và độ sâu kiến trúc. Điều này khẳng định vai trò quan trọng của việc khai thác các biểu diễn trung gian và cơ chế căn chỉnh có nhận thức tầm quan trọng trong bài toán chất lọc tri thức cho mô hình ngôn ngữ lớn.

Tuy nhiên, đề án vẫn còn tồn tại một số hạn chế. Việc lựa chọn các siêu tham số như số lượng tầng được chọn, hệ số kết hợp giữa ánh xạ hình học và ngữ cảnh, cũng như trọng số giữa các thành phần hàm mất mát hiện vẫn dựa nhiều vào kinh nghiệm và thử nghiệm thủ công. Ngoài ra, chi phí tính toán của các bước căn chỉnh dựa trên Optimal Transport vẫn còn tương đối lớn khi mở rộng sang các mô hình hoặc tập dữ liệu có quy mô lớn.

5.2 Hướng phát triển trong tương lai

Từ những kết quả và hạn chế đã phân tích, một số hướng phát triển có thể được nghiên cứu trong tương lai như sau:

- Phát triển các cơ chế tự động học hoặc tối ưu hóa siêu tham số nhằm điều chỉnh số lượng tầng được chọn và trọng số giữa các thành phần trong hàm mất mát một cách thích nghi theo từng cặp mô hình và từng nhiệm vụ.
- Mở rộng phạm vi căn chỉnh sang các thành phần biểu diễn khác của mô hình, chẳng hạn như các ma trận chú ý (attention) hoặc các đặc trưng trung gian khác, nhằm truyền tải tri thức đa chiều và toàn diện hơn.
- Kết hợp phương pháp đề xuất với các kỹ thuật tối ưu mô hình như cắt tỉa (pruning), lượng tử hóa (quantization) hoặc huấn luyện hiệu quả bộ nhớ nhằm xây dựng các mô hình học sinh nhỏ gọn nhưng vẫn đảm bảo chất lượng.

Nhìn chung, đề án đã đề xuất một hướng tiếp cận hiệu quả cho bài toán chất lọc tri thức trong các mô hình ngôn ngữ lớn thông qua việc khai thác và căn chỉnh các biểu diễn tầng ẩn một cách có chọn lọc và linh hoạt, góp phần thu hẹp khoảng cách giữa các mô hình khác nhau về tokenizer và kiến trúc.

TÀI LIỆU THAM KHẢO

- [1] X. Cui, M. Zhu, Y. Qin, L. Xie, W. Zhou **and** H. Li, “Multi-level optimal transport for universal cross-tokenizer knowledge distillation on language models,” *in Proceedings of the AAAI Conference on Artificial Intelligence* **volume** 39, 2025, **pages** 23 724–23 732.
- [2] S. Zhang, X. Zhang, Z. Sun, Y. Chen **and** J. Xu, “Dual-space knowledge distillation for large language models,” *arXiv preprint arXiv:2406.17328*, 2024.
- [3] M. A. Haidar, N. Anchuri, M. Rezagholizadeh, A. Ghaddar, P. Langlais **and** P. Poupart, “RAIL-KD: RANdom intermediate layer mapping for knowledge distillation,” *in Findings of the Association for Computational Linguistics: NAACL 2022* M. Carpuat, M.-C. de Marneffe **and** I. V. Meza Ruiz, **editors**, Seattle, United States: Association for Computational Linguistics, **july** 2022, **pages** 1389–1400. DOI: 10 . 18653 / v1 / 2022 . findings - naacl . 103 **url**: <https://aclanthology.org/2022.findings-naacl.103/>
- [4] J. Bai **and others**, “Qwen technical report,” *arXiv preprint arXiv:2309.16609*, 2023.
- [5] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, I. Sutskever **and others**, “Language models are unsupervised multitask learners,” *OpenAI blog*, **jourvol** 1, **number** 8, **page** 9, 2019.
- [6] F. Jiang, “Identifying and mitigating vulnerabilities in llm-integrated applications,” *mathesis*, University of Washington, 2023.
- [7] P. Zhang, G. Zeng, T. Wang **and** W. Lu, “Tinylama: An open-source small language model,” *arXiv preprint arXiv:2401.02385*, 2024.
- [8] A. Yang **and others**, “Qwen2.5 technical report,” *arXiv preprint arXiv:2412.15115*, 2024.
- [9] C. Villani **and others**, *Optimal transport: old and new*. Springer, 2008, **volume** 338.
- [10] J. Lv, H. Yang **and** P. Li, “Wasserstein distance rivals kullback-leibler divergence for knowledge distillation,” *Advances in Neural Information Processing Systems*, **jourvol** 37, **pages** 65 445–65 475, 2024.
- [11] S. Fan **and others**, *Not all layers of llms are necessary during inference*, 2024. arXiv: 2403 . 02181 [cs.CL]. **url**: <https://arxiv.org/abs/2403.02181>

- [12] X. Men **and others**, *Shortgpt: Layers in large language models are more redundant than you expect*, 2024. arXiv: 2403 . 03853 [cs.CL]. **url:** <https://arxiv.org/abs/2403.03853>
- [13] M. Cuturi, “Sinkhorn distances: Lightspeed computation of optimal transport,” *Advances in Neural Information Processing Systems*, **jourvol** 26, 2013.
- [14] M. Conover **and others**, *Free dolly: Introducing the world’s first truly open instruction-tuned llm*, 2023.
- [15] Y. Wang **and others**, *Benchmarking generalization via in-context instructions on 1,600+ language tasks*, 2022. arXiv: 2204 . 07705. **url:** <https://arxiv.org/abs/2204.07705>
- [16] W.-L. Chiang **and others**, *Vicuna: An open-source chatbot impressing gpt-4 with 90%* chatgpt quality*, LMSYS Blog, 3(5), 2023. **url:** <https://lmsys.org/blog/2023-03-30-vicuna>
- [17] Y. Chen, Y. Liu, L. Chen **and** Y. Zhang, *Dialogsum: A real-life scenario dialogue summarization dataset*, 2021.
- [18] Y. Wang **and others**, *Self-instruct: Aligning language model with self generated instructions*, 2022.
- [19] C.-Y. Lin, “Rouge: A package for automatic evaluation of summaries,” *in Text summarization branches out* 2004, **pages** 74–81.
- [20] E. J. Hu **and others**, “Lora: Low-rank adaptation of large language models,” *arXiv preprint arXiv:2106.09685*, 2021.
- [21] N. Boizard, K. El Haddad, C. Hudelot **and** P. Colombo, “Towards cross-tokenizer distillation: The universal logit distillation loss for llms,” *arXiv preprint arXiv:2402.12030*, 2024.

Appendices